

Gradu Amaierako Lana
Informatika Ingeniaritzako Gradua
Konputazioa

**Itzaldutako datuetan inferentzia ereduen
eraginkortasunaren azterketa**

Gorka Puente Díez

Zuzendariak
Iñigo Perona Balda

2026ko abuztuaren 30a

Laburpena

Gradu Amaierako Lan honetan Ikasketa Automatikoko eta Ikasketa Sakoneko ereduak informazio-itzaletan, hau da, entrenamenduko ikasketa-prozesuari nahita ezkutatu-tako datu-eremu egituratuetan (*information shadows*), eta ezagutzen ez dituzten distribuzioz kanpoko sarreren (OOD, ingelesez *Out-of-Distribution*) aurrean duten portaera probabilistikoa eta ziurgabetasunaren estimazioa aztertzen dira, sailkatze zein erregresio problemak barne hartuz. Sare Neuronal Sakon Estandarretan (SDNN, ingelesez *Standard Deep Neural Networks*), pisu bakoitza balio eskalar finko bat denez (eredu deterministak), eredu hauek konfiantza larria erakusteko joera dute ikusi gabeko sarrerei erantzuteko garaian. Gabezia hori aztertzeke eta soluzio bat bilatzeko, Python bidezko software-azpiegitura modular eta polimorfiko bat garatu da, datu sintetiko unidimentsional zein bidimentsionaletan, MNIST eta CIFAR-10 irudietan zein Weka ML proiektutik hautatutako datu-base tabularretan esperimentu egituratuak exekutatzea ahalbidetzen duena.

Horretarako, informazio-itzalen injekzioa eta zatiketa estrategikoak ezarri dira sarrerako eremu ezberdinetan ereduak ziurgabetasun-maila neurtzeko, erregresioan iragarpenen bariantza erabiliz eta sailkapenean Shannon-en entropia hautatuz. Lortu-tako emaitzek erakusten dute sare neuronal estandarrek konfiantza larria erakusteko joera dutela ikusi gabeko datuetan, baina eredu probabilistikoek eta aurrerago azalduko den Ensemble sailkatzaileak ezjakintasuna modu naturalean aitortzen dutela, itzaldutako sarreren detekzio zehatzagoa ahalbidetuz. Azkenik, garatutako arkitektura eskuz idatzitako karaktereak errekonozitzeko denbora errealeko web aplikazio interaktibo batean balioztatu da, ereduak ikasketa jarraitua eta egokitzen dinamikoa ahalbidetuz.

Garapen Jasangarrirako Helburuak

Gradu Amaierako Lan hau Garapen Jasangarrirako 2030 Agendarekin eta Nazio Batuen Garapen Jasangarrirako Helburuekin (GJH) lerrokatzen da (1 Irudia). Ikasketa Automatikoko ereduaren fidagarritasuna eta ziurgabetasunaren estimazioa ikertuz, proiektuak hiru helburu nagusiri egiten die ekarpen zuzena:



1 Irudia: Garapen Jasangarrirako 2030 Agendako Helburuak (GJH).

- **9. Helburua: Industria, Berrikuntza eta Azpiegitura.** Informatika Fakultateko ikerketa-ildo estrategikoekin bat etorriz, lan honek ikerketa zientifiko eta teknologiko aurreratua bultzatzen du. Industria automatizatuan, osasungintzan eta azpiegitura digital kritikoetan erabakiak hartzen dituzten adimen artifizialeko erduei beren ezjakintasuna neurtzeko gaitasuna ematen zaie. Horrela, eredu deterministek eragindako akats larriak saihestu eta azpiegitura teknologiko sendoagoak, fidagarriagoak eta seguruagoak eraikitzen laguntzen da.
- **10. Helburua: Desberdintasunak Murriztea.** Egungo datu-baseetan sozialki baztertutako edo gutxiengo diren kolektiboek presentzia txikiagoa izan ohi dute, eta horrek egiturazko hutsuneak zein informazio-itzalak eragiten ditu ereduetan. Eredu konbentzionalek komunitate horiei buruzko iragarpen diskriminatzaileak egiten dituzte gehiegizko konfiantza faltsuarekin. Proiektu

honetan garatutako ziurgabetasunaren kuantifikazioak ereduari aukera ematen dio datu nahikorik ez duela aitortzeko, diskriminazio algoritmikoa prebenituz eta erabaki ekitatiboagoak sustatuz.

- **16. Helburua: Bakea, Justizia eta Erakunde Sendoak.** Sistema automatizatuen gardentasuna eta erantzukizun etikoa bermatzea ezinbestekoa da gizarte bidezkoago bat eraikitzeko. Eredu probabilistikoek eta giza begizta aktiboak algoritmo zintzoagoak lortzeko bidea eskaintzen dute, erabakiak itsu-itsuan hartu beharrean, giza ikuskaritza aktibatzen baitute ziurgabetasun handiko egoeretan.

Gaien aurkibidea

Gaien aurkibidea	v
Irudien aurkibidea	viii
Taulen aurkibidea	x
1 Sarrera eta Motibazioa	1
1.1 Testuingurua eta Motibazioa	1
1.2 Proiektuaren Helburuak	2
1.3 Memoriaren Egitura	3
2 Proiektuaren Kudeaketa eta Planifikazioa	5
2.1 Garapen Metodologia eta Arkitekturaren Oinarria	5
2.2 Proiektuaren Deskonposaketa, LDE	6
2.3 Atazen Denbora Estimazioak, GANTT eta Bide Kritikoa	6
2.3.1 Proiektuaren Bilakaera eta Kronologia	7
2.4 Arriskuen eta Desbideratzeen Analisia	8
3 Oinarri Teorikoak eta Artearen Egoera	11
3.1 Sare Neuronal Bayesiarrak eta Probabilitate Inferentzia	11
3.1.1 Bariaziozko inferentzia eta ELBO Froga Matematikoa	11
3.1.2 Reparameterization Trick implementazioan	13
3.2 Multzokapen Probabilistikoak eta Hurbilketak	13
3.2.1 Monte Carlo Dropout Hurbilketa	14
3.2.2 Deep Ensembles Metodologia	14
3.2.3 Random Forest Ereduaren Bariantza Natiboa	14
3.2.4 Erregresio-metrikak eta Batez Besteko Errore Koadratikoa	14
3.3 Ziurgabetasunaren Estimazioa eta Entropia	15
3.3.1 Softmax Funtzioaren Mugak eta <i>Energy Score</i>	15
3.3.2 Shannon Entropiaren Banaketa Bimodala	15
3.4 Egiturazko Balioztatzea eta Informazio-itzalen Detekzioa	16
3.4.1 Conformal Prediction eta Muga Estatistikoak	16
3.4.2 Kluster bidezko Balioztatze Gurutzatua	17
4 Garapen Tresnak eta Ingurune Teknologikoa	19
4.1 Garapen Ingurunea	20
5 Diseinua eta Arkitektura	21

5.1	Arkitektura Modularren Ikuspegi Orokorra	21
5.2	UML Klase-Diagrama eta Interfazeak	22
5.3	Sekuentzia-Diagrama eta Exekuzio-Fluxua	22
5.4	Datuen Kudeaketa eta Polimorfismoa	22
5.4.1	Interfaze Estandarra	22
5.4.2	Datu Sintetikoaren Sorkuntza	23
5.4.3	Irudien Prozesamendua eta Estandarizazioa	23
5.4.4	Datu-Base Tabularrak eta Weka Iragazkiak	24
5.5	Informazio-Itzalen Injekzioa, <code>shadows.py</code>	24
5.5.1	Datu Sintetikoetako Itzalak	24
5.5.2	Irudietako Itzalak	25
5.5.3	Datu Tabularren Itzalak	25
5.6	Datuen Banaketa Egituratua, <code>splitter.py</code>	25
5.7	Ikasketa Ereduek <code>models.py</code> , <code>classifiers.py</code> eta <code>ensemble.py</code> Fitxategietan	26
5.7.1	Arkitektura Matematikoa, <code>models.py</code>	26
5.7.2	Sailkatzaileen Interfaze-Egokitzapena, <code>classifiers.py</code>	27
5.7.3	Ereduen Bateratzea, <code>ensemble.py</code>	27
5.8	Sistemaren Bihotza, Orkestratzailea	28
5.9	Osagarri Gehigarriak: Laguntza-Moduluak	28
5.9.1	Zarataren Injekzioa, <code>noise.py</code>	28
5.9.2	Emaitzen Bistaratzea, <code>visualization.py</code>	29
5.9.3	Itzaldutako Datuen Detektatzailea, <code>interpreter.py</code>	29
5.10	Aplikazio Interaktiboa eta Ikasketa Jarraitua	30
6	Esperimentuak eta Emaitzak	31
6.1	Datu Sintetikoaren Esperimentuak	31
6.2	Ekarpen Metodologikoa: Random Forest eta MC Dropout Hibridazioa	33
6.3	Irudien Sailkapen Esperimentuak (MNIST eta CIFAR-10)	34
6.3.1	CIFAR-10 Koloretako Irudien Esperimentua	37
6.4	Datu tabularren bidez balioztapena	38
6.5	Karaktereen Web Aplikazioaren Balioztatze Interaktiboa	41
7	Ondorioak eta Etorkizuneko Lanak	45
7.1	Ondorio Nagusia	45
7.2	Esperimentazio-Ardatzen Emaitza	45
7.3	Garatutako Ereduen eta Esperimentuen Mugak eta Gabeziak	47
7.4	Etorkizuneko Lan Illoak	48
A	AA sortzailearen erabilera deklarazioa	49
B	Erabiltzailearen eta Inplementazioaren Manuala	51
B.1	Software Betebeharrak eta Ingurunea	51
B.2	Esperimentu Koadernoaren Exekuzioa	52
B.3	Karaktereen Web Aplikazioaren Erabilera (3.1.4 Esperimentua)	52
C	Koadernoaren eta Esperimentuen Inbentario Osoa	53

D	Hiperparametroak eta Ereduen Konfigurazioak	55
E	Esperimentazioaren Emaitza eta Grafiko Gehigarriak	57
E.1	Datu Sintetikoak eta Erregresio Ez-linealaren Ebaluazioa	57
E.2	Ziurgabetasun Probabilistikoa eta Bariaziozko Inferentzia	59
E.3	Irudien Ezkutatze Eszenatokiak: Eredu Estandarrak vs. Ensemble Bimodala	61
E.4	Weka Datu Tabularretako PCA Kluster-Itzalen Galeria Osoa	62
	Bibliografia	65


Irudien aurkibidea

1	Garapen Jasangarrirako 2030 Agendako Helburuak (GJH).	iii
2.1	LDE-ren arbola-diagrama xehatua.	7
2.2	Proiektuaren GANTT kronograma eta garapen-esperimentazio iteratibo jarraitua.	8
3.1	Sare neuronal konbentzionalen eta Sare Neuronal Bayesiarren arteko egiturazko konparazioa, pisu finko zein probabilitistikoak adieraziz.	12
3.2	Shannon entropiaren dentsitate-banaketak KDE bidez: (a) emaitza onak eredu kalibratu batean, bi tontorrak ongi bereizita eta τ^* muga finkatuz ziurtasuna zehaztasunez detektatuz; (b) emaitza kaxkarrak gainezarpinarekin, ereduak itzaletan gehiegizko konfiantza duenean ziurtasuna bereiztea galaraziz.	16
5.1	Sistemaren arkitektura modularren prozesu-fluxu osoa.	21
5.2	Sistemaren UML Klase-Diagrama polimorfikoa eta egiturazkoa.	22
5.3	UML Sekuentzia-Diagrama mezu-trukaketaren bizi-ziklo garbia irudikatuz.	23
6.1	Random Forest erregresorearen ziurgabetasun-banda informazio-itzalaren eremuan, 2.0.1 koadernoko esperimentutik lortua.	32
6.2	Random Forest Classifier ereduako Konfusio Matrizea eta Entropiaren Banaketa, 3 zifra ezkutatzean (3.1.3 koadernotik).	35
6.3	MC Dropout Classifier ereduako Konfusio Matrizea eta Entropiaren Banaketa, 3 zifra ezkutatzean (3.1.3 koadernotik).	35
6.4	Ensemble Classifier (RF + MC Dropout) ereduako Konfusio Matrizea eta Entropiaren Banaketa Bimodala, 3 zifra ezkutatzean (3.1.3 koadernotik).	36
6.5	Weka Quake datu-multzoko datuen proiektzioa PCA bidez 2D-n	38
6.6	Weka datu-base tabularretan Kluster Bidezko Balioztatze Gurutzatuarekin eredu ezberdinek (RF, BNN eta Ensemble) lortutako OOD Detekzio Zehaztasunaren konparaketa-grafikoa. Marra gorriak zoriaren erreferentzia adierazten du (%50), laginak ezagunak ala itzalekoak diren bereiztean.	40
6.7	Karaktereen Web Aplikazioa ‘7’ zifra ezaguna marraztean.	42
6.8	Karaktereen Web Aplikazioa ‘Q’ karaktere ezezaguna marraztean.	42
6.9	Karaktere berria irakasteko interfazea.	43
6.10	Fase-egiaztapeneko oharra.	43
6.11	Ikasketa jarraituko lagin-bilketa.	44
6.12	Birrentrenatutako ereduaren (v61c9d4) inferentzia arrakastatsua.	44

E.1	Erregresio linealaren porrota funtzio sinusoidal ez-linealean, kurbadura ikasi ezinik desbideratze handia sortuz (1.2.0 koadernotik).	58
E.2	Koadernoetako eredu arrakastatsuak kurba zirkularreko itzalean, bigarren mailako polinomiala ezkerrean eta Random Forest eskuinean (1.2.1 koadernotik).	58
E.3	MC Dropout sareen ebaluazioa $p = 0.20$ ezkerrean eta $p = 0.40$ eskuinean, itzalpeko gehiegizko konfiantza eta ikusgaiko ezjakintasun desegokia erakutsiz (2.2 koadernotik).	59
E.4	Sare Neuronal Bayesiarren porrot esperimentalak datu sintetikoetan . . .	60
E.5	MNIST entropia-dentsitateen konparaketa, MC Dropout isolatuaren gainkonfiantza ezkerrean eta Ensemble ereduaren bimodalitate garbia eskuinean (3.1 eta 3.1.3 koadernoetatik).	61
E.6	CIFAR-10 irudietan entropia-banaketen analisia eta dimentsionaltasun handiaren ondorioak (3.2 koadernotik).	61
E.7	Weka datu-base tabularretan PCA dimentsio-murrizketa eta k-means bidezko zentroide isolatuen informazio-itzaletan galeria osoa (4.1 eta 4.3 koadernoetatik).	62
E.8	Weka datu-base tabularretan kluster bidezko baliozkotze gurutzatuarekin eredu desberdinek lortutako OOD detekzio-zehaztasunaren konparaketa (4.3 koadernotik).	63

Taulen aurkibidea

2.1	LDE lan-paketeen laburpena.	6
2.2	Atazen denbora-estimazioak eta atazen arteko loturak.	7
2.3	Arriskuen ebaluazio-matrizea eta kudeaketa-neurriak.	9
6.1	50 funtzio sintetikoetan 8 erregresio-ereduren konparaketa- <i>benchmark</i> orokorra (1.2.3 koadernotik lortua).	32
6.2	MNIST irudietan klase bakarra ezkutatzearen konparaketa-benchmarka: 3 (Hasierako Kasu Nagusia) vs 1 (Entropia Baxueneko Zifra, 3.1.3 koadernotik).	34
6.3	MNIST irudietan antzeko ezaugarri bisualak dituzten klase-multzoa [3, 5, 8] ezkutatzearen lortutako emaitzak (3.1.3 koadernotik).	34
6.4	CIFAR-10 koloretako irudietan 3 klasea (Katua) ezkutatzearen lortutako konparaketa eta OOD detekzioaren zehaztasuna (3.2 koadernotik).	37
6.5	Ohiko balioztatze gurutzatuaren (MSE_{Vis}) eta informazio-itzaileko ebaluazioaren (MSE_{Shadow}) arteko konparaketa eredu ezberdinetan.	39
6.6	Weka datu-base tabularretan Kluster Bidezko Balioztatze Gurutzatuarekin eredu ezberdinek lortutako OOD Detekzio Zehaztasuna eta Ezjakintasun Ratioak.	39
C.1	Proiektuko esperimentu eta koadernoaren inbentario zein laburpen tekniko osoa (3.1.4 esperimentua web aplikazio interaktibo gisa garatu baita).	53
D.1	Esperimentuetan erabilitako eredu probabilistikoen hiperparametroen konfigurazio osoa.	55



Sarrera eta Motibazioa

1.1 Testuingurua eta Motibazioa

Mundu errealeko aplikazioetan, sarritan gertatzen da inferentzia egiteko erabiltzen diren datuak entrenamendu-fasean ikusitakoetatik oso desberdinak izatea. Datu horiei testuan zehar informazio-itzalak deritze (*information shadows*), hau da, ausazko datu-estalduraren hutsune soilak (*data gaps*) izan beharrean, ikasketa-ereduari entrenamenduan apropos ezkutatzen zaizkion egiturazko eremu eta ezagutza-mugak. Izan ere, Srivastava eta Chatterjeeren [1] azken ikerketa teorikoek nabarmendu duten bezala, informazio-itzalek ereduak berez eskuratu ezin dituzten fenomenoek egiturazko mugak definitzen dituzte, eta eremu horietan fidagarritasunez jarduteko ezinbestekoa da itzalen kontzientzia duen ziurgabetasunaren estimazioa (*shadow-aware uncertainty*) garatzea. Entrenamendu-eremuetatik kanpo zehaztasuna galtzeko arriskuaz gain, arazo larriagoa da ereduak erantzun okerrak probabilitate eta ziurtasun altuegi bidez emateko duten joera, hau da, gehiegizko konfiantza delakoa, bereziki datu-base txikiak erabiltzen direnean.

Diagnostiko medikoan, gidatze autonomoan edo industria-kontrolako sistema kritikoetan, iragarpen soil bat itzultzea ez da nahikoa, ezinbestekoa baita sistemak emandako iragarpenarekin zenbateraino fida daitekeen zehaztea. Medikuntzan, adibidez, pazienteen pribatutasun-politika zorrotzen ondorioz, ezinezkoa izaten da datu-multzo handiak zentralizatzea. Horren ordez, osasun-zentro bakoitzak datu-base lokal txikiak kudeatzen ditu, eta horrelako inguruneetan patologia zein ezaugarri jakinen arteko egiturazko hutsuneak egotea oso gertagarria da.

Proiektu honen oinarrizko motibazioa proiektuko zuzendariak aurrez bideratutako ikerketa-kasu praktiko batetik sortu zen. Ikerketa horretan, ordenagailu-ikusmena eta web-kamera bidezko begiradaren estimazioa erabiliz erabiltzaileak pantailan begiratzen zion puntu zehatza iragartzeko sare neuronalak garatu ziren. Kalibrazio-fasean puntu zehatz eta murriztu batzuk soilik erabili zirenez, sare neuronal tradizionalak emaitza oso kezagarriak eta gain-ziurtasun handia erakutsi zituzten tarteko puntu ikusi gabeetan, interpolazio-teknika klasikoek nagusitasuna agerian utziz eremu ezjakinetan.

Bereizketa kontzeptual argi bat egin behar da datu-estalduraren hutsune soilen (*data gaps*) eta benetako informazio-itzaletan (*information shadows*) artean. Alde batetik, entrenamenduan ikusitako laginen artean geratzen diren tarteko hutsuneak berreraikitzea gutxi gora-behera egingarria da interpolazio bidez, ereduak ezagutzen dituen muturren arteko erlazioak jarraitzen baititu. Bestetik, ereduari entrenamenduan ezkutatzen zaizkion egiturazko eremuak edo ikusi gabeko banaketak ez dira datu-falta puntualak, ezagutza-mugak baizik. Eremu horietan erantzuteak ezagutza berria sortzea eskatzen du, eta sare neuronal arruntek, beren mugez jabetu gabe, konfiantza larri osoz erantzuteko joera dute.

Fenomeno hau era grafikoan ulertzeko adibide argi bat hizkuntzaren prozesamenduko hitz-kapsulatzeetan (*word embeddings*) aurki daiteke. Espazio bektorial batean antzeko hitzen arteko tartekak interpolatzea bideragarria da, kontzeptu ezagunen arteko distantzia semantikoak definituta daudelako. Ordea, espazio horretan inoiz txertatu ez den kontzeptu edo domeinu bati buruz galdetzean, sistemak ezin du aurrez ikusitako erlazioetatik erantzunik eratorri. Hori dela eta, ezinbestekoa da ereduak tarteko datu-hutsuneen eta benetako informazio-itzaletan arteko mugak bereiztea.

Eredu neuronalek entrenamenduko puntu isolatuetatik kanpo, hau da, informazio-itzaletan, zuten ezjakintasuna adierazteko ezintasunak galdera zientifiko nagusia mahairatu zuen: Nola jokatzan dute eredu probabilistiko eta sakonek ikusi gabeko eremuetan eta nola kuantifikatu daiteke beren ziurgabetasuna modu fidagarri batean?

Galdera honi erantzuteko, ezinbestekoa bilakatzen da ereduak egituraz eremuak ezkutatzea, informazio-itzalak sortuz, eta asmatze-tasari soilik erreparatu beharrean, ereduaren ziurtasuna eta ezjakintasuna neurtzeko metodologietan sakontzea.

Gure lanean probabilitate-egitura nagusiak bi arazo motatan bereizten dira.

- **Erregresio-iragarpenak.** Balio jarraituak iragartzen direnean, ereduaren bariantza eta desbideratze estandarra erabiltzen dira ziurgabetasun maila gisa.
- **Sailkatze-iragarpenak.** Klase anitzeko iragarpenetan, neurketa nagusi gisa Shannon-en entropia erabiltzen da. Eredu kalibratu baten ezaugarria da datu ikusgarrien entropia balio txikietan kokatzea ($H(p) \approx 0$) eta informazio-itzal ezezagunen entropia balio handietan kontzentratzea ($H(p) \approx \log K$), bere ezjakintasuna modu naturalean aitortuz.

1.2 Proiektuaren Helburuak

Proiektu honen xede eta helburu nagusia hurrengoa da:

Ikasketa Automatikoko eredu desberdinek ezagutzen ez dituzten datuen aurrean duten portaera aztertzea, haien ziurgabetasunaren adierazpen egokia bilatuz.

Helburu nagusi horretara iristeko eta analisia era progresiboan eraikitzeko, proiektua datuen konplexutasun mailaren arabera **hiru fase nagusitan** egituratu da:

1. **Datu sintetikoak.** Problema unidimentsional eta bidimentsionalen bidez, oinarrizko ereduen portaera eta bariantza aztertzen dira lehenik, ziurgabetasunaren neurtze-mekanismoak balioztatzeke ingurune erabat kontrolatu batean.
2. **Irudi datuak eta aplikazio interaktiboa.** Ikasketa sakoneko ereduetara igaroz, irudien sailkapena lantzen da MNIST eta CIFAR-10 datu-baseak erabiliz, eta informazio-itzalak aplikatuz entropia-dentsitateen bimodalitatea ebaluatzen da. Horrez gain, garatutako probabilitate-egituran eta interpretatzailean oinarrituta, eskuz idatzitako karaktereak errekonozitzeko web aplikazio interaktibo bat garatu da, MNISTeko digituak erabiliz, sistemaren informazio-itzelean erortzen diren edozein karaktere berri denbora errealean detektatzen du eta ikasketa jarraituaren bidez kategoria berriekin ereduak berriro entrenatzeko aukera ematen dio erabiltzaileari.
3. **Datu-base tabular konplexuak.** Azkenik, proiektuaren aurkikuntzak mundu errealeko arazoetara estrapolatzen dira Weka ML proiektuak gomendatutako datu-base tabular batzuk erabiliz, non eredu klasiko, sare neuronal eta *ensemble* desberdinen orokortze-ahalmena egiaztatzen den datuen kluster partizioan oinarritutako baliozkotze gurutzatuaren bidez.

1.3 Memoriaren Egitura

Proiektuaren garapena eta emaitzak modu egituratuan aurkezteko, memoria hau honako kapitulu hauetan banatu da.

- **2. Kapitulu. Proiektuaren Kudeaketa eta Planifikazioa.** Metodologia iteratiboa, LDE egitura, denbora-estimazioak, GANTT kronograma, bide kritikoa eta arriskuak azaltzen dira.
- **3. Kapitulu. Oinarri Teorikoak eta Artearen Egoera.** Ikasketa Automatikoko ziurgabetasunaren aurreikuspenean gaur egun erabiltzen diren metodologiak, Sare Bayesiarrak, Bariaziozko inferentzia, Monte Carlo Dropout eta Conformal Prediction muga estatistikoak azaltzen dira.
- **4. Kapitulu. Garapen Tresnak eta Ingurune Teknologikoa.** Garapean erabilitako lengoaiak, Python esaterako, garapen inguruneak eta liburutegiak zehazten dira.
- **5. Kapitulu. Diseinua eta Arkitektura.** Sistemaren moduluen azalpenan zentratzen da: datuen sorkuntza, itzalen kudeaketa, eredu probabilitistikoaren interfazeak, orkestratzailea, interpretatzailea eta web aplikazioaren arkitektura interaktiboa.
- **6. Kapitulu. Esperimentuak eta Emaitzak.** Gauzatutako ebaluazio frogak erakusten dira, datu-moten progresioa jarraituz: datu sintetikoaren desbideratzeak, irudien bimodalitatea, Weka balioztatze-gurutzatuak eta web aplikazioaren denbora errealeko distribuzioz kanpoko (OOD) detekzioaren emaitzak.

- **7. Kapitula. Ondorioak eta Etorkizuneko Lanak.** Lortutako ondorio nagusiak bildu eta etorkizunera begira irekitzen diren ikerketa-ildoak azaltzen dira.

Azkenik, ikerketaren erreproduzigarritasun zientifikoa bermatzeko eta garatutako software-azpiegitura komunitatearen eskura jartzeko, proiektuaren iturburu-kode osoa, koadernoak eta web aplikazioa GitHub biltegiko estekan daude eskuragarri (<https://github.com/gorkiuss/informazio-itzalak-ziurgabetasuna>).

Proiektuaren Kudeaketa eta Planifikazioa

Ikasketa Automatikoko eta Ingeniaritza Informatikoko proiektu honetan plangintza tekniko eta metodologiko zorrotza ezarri da. Kapitulu honetan sistemaren garapena bideratu duten kudeaketa-tresna nagusiak aurkezten dira: garapen-metodologia iteratiboa, Lanaren Deskonposaketa Eredua, LDE, atazen denbora-estimazioak, GANTT kronograma, bide kritikoaren analisia eta arriskuen kudeaketa.

2.1 Garapen Metodologia eta Arkitekturaren Oinarria

Ikerketaren izaera esperimentalta eta softwarearen garapen modularra bateratzeko, **garapen-metodologia sekuentzial eta iteratiboa** ezarri da. Oinarrizko arkitektura teknikoa eta klase abstraktu nagusiak hasieratik garatu dira erabat:

- Datu-sortzaileak: `BaseDataGenerator`.
- Informazio-itzalak: `BaseShadow`.
- Eredu probabilitistikoak: `BaseClassifier`.
- Prozesu-kudeaketa: `ClassificationOrchestrator` eta `Splitter`.

Oinarri sendo honen funtzionamendua eta softwarearen kalitatea 1.x esperimentu-koaderno bidez balioztatu eta frogatu ziren hasierako fasean.

Behin oinarrizko egitura abstraktua sendotuta, prozesuak garapena eta esperimentazioa etengabe txandakatu dituen egitura jarraitu du.

Oinarrizko Arkitektura $\longrightarrow$ 1.x Kalitate Probak $\longrightarrow$ Esperimentazio Berriak $\longrightarrow$ Modulu Zehatzen Egokitzea (2.1)

Horrela, koaderno zientifiko berri bakoitzarekin (2.x, 3.x, 4.x) eredu eta itzal zehatzen inplementazioak garatu dira, hasierako oinarrizko arkitektura abstraktua ukigabe mantenduz.

2.2 Proiektuaren Deskonposaketa, LDE

Proiektuaren konplexutasuna kudeatzeko eta lan-karga modu orekatuan banatzeko, LDE ezarri da. Ereduek honen bidez, helburu nagusia lau lan-adar nagusitan eta hamaika lan-pakete espezifikotan egituratu da.

1. **Dokumentazioa eta Ikerketa Adarra.** Artearen egoera, eredu probabilistikoen oinarri matematikoak, Shannon-en entropia, aldagai biko aldakortasuna eta OOD detekzioaren literatura.
2. **Garapen Teknologikoaren Adarra.** Sistemaren arkitektura modularra, datu-sortzaileak, informazio-itzalak, ereduaren klase base abstraktuak, BNN, MC Dropout eta Random Forest adaptadoreak, orkestratzailea, interpretatzailea eta web aplikazio interaktiboa.
3. **Kudeaketa Adarra.** Proiektuaren definizioa, denbora planifikazioa, arriskuen jarraipena, GJH analisia eta tutoretzetako bilerak.
4. **Memoria eta Balioztatzea Adarra.** Esperimentazio-faseak koadernoetan, emaitzen azterketa eta memoriaren idazketa.


Azpiarraztekoa da denbora-dedikazio nagusia oinarritzko arkitektura teknikoaren implementazioan eta 1.x esperimentu-koadernoetan (T2.1: 60h) kontzentratu dela. Hasiera-hasieratik oinarri modular eta sendoa bat garatzeko hautua egin denez, behin oinarritzko egitura abstraktuak funtzionatzean, ondorengo faseen (2.x, 3.x eta 4.x esperimentuak) garapena eta esperimentazioa askoz errazagoa, arinagoa eta eraginkorragoa gertatu dira (T2.2: 25h, T2.3: 25h, T2.4: 30h, T4.1: 20h). Horrez gain, web aplikazioaren *frontend*-a, HTML5 Canvas interaktiboa, CSS3 interfazea eta JavaScript osagaiak, LLM bidezko azelerazio teknikekin prototipatu direnez, ataza honen dedikazioa 15 ordura mugatu da (T2.5: 15h).

Adarra	Lan-Paketea	Deskribapen Laburra
Dokumentazioa	LP1.1 - Bibliografia	Artikuluak eta OOD literatura aztertzea.
Dokumentazioa	LP1.2 - Oinarri Teorikoak	Ziurgabetasun probabilistikoaren, Shannon entropiaren eta OOD mugen formulazioa.
Garapena	LP2.1 - Datuak eta Oinarritzko Sistema	1D/2D sintetikoak, Splitter, Orkestratzailea eta 1.x esperimentuak (60h).
Garapena	LP2.2 - Oinarri Abstraktuak	<code>BaseClassifier</code> eta interfaze polimorfikoak.
Garapena	LP2.3 - Ereduek Zehatzak	BNN, MC Dropout eta RF adaptadoreak egokitzea.
Garapena	LP2.4 - Interpretatzailea	<code>UncertaintyInterpreter</code> eta irudien esperimentuak (3.x).
Garapena	LP2.5 - Web Interfazea	HTML5 Canvas interaktiboa eta Flask zerbitzaria (15h).
Kudeaketa	LP3.1 - Bilerak	Tutoretza-bilerak eta zuzenketa jarraipena.
Kudeaketa	LP3.2 - Plangintza	GANTT kronograma, arriskuen analisia eta GJH.
Memoria	LP4.1 - Esperimentazioa	1D/2D, MNIST eta Weka analisia koadernoetan.
Memoria	LP4.2 - Idazketa	Sarrera, Diseinua, Emaitzak eta Memoria idaztea.

2.1 Taula: LDE lan-paketeen laburpena.

2.3 Atazen Denbora Estimazioak, GANTT eta Bide Kritikoa

Proiektuaren iraupen osoa 300 lan-ordu ingurutan estimatu da, 12 Kreditu ECTS-en karga akademikoari jarraituz, 16 astetan zehar banatuta. Lan-pakete bakoitzaren



2.1 Irudia: LDE-ren arbola-diagrama xehatua.

denbora-banaketa eta mendekotasunak 2.2 taulan biltzen dira.

Kod.	Atazaren Izena	Orduak (h)	Mendekotasunak
T1.1	Bibliografia eta OOD Literatura Aztertzea	20	Ez dago
T1.2	Eredu Probabilistikoen eta Ziurgabetasun Mugen Formulazioa	20	T1.1
T2.1	Oinarrizko Sistema, Orkestratzailea, Splitter eta 1.x Esperimentuak	60	T1.1
T2.2	Ereduen Klase Base Abstraktuak Diseinatzea	25	T1.2, T2.1
T2.3	BNN, MC Dropout eta RF Adaptadoreak (2.x)	25	T2.2
T2.4	UncertaintyInterpreter eta Irudien Esperimentuak (3.x)	30	T2.3
T2.5	Karaktereen Web Aplikazio Interaktiboa Garatzea	15	T2.4
T3.1	Tutoretza Bilerak eta Jarraipena	15	Ez dago
T3.2	Plangintza, GANTT, Arriskuak eta GJH Analisia	15	T3.1
T4.1	Datu Tabularren Esperimentazioa eta Weka (4.x)	20	T2.4
T4.2	Azken Memoria Idaztea eta Dokumentatzea	55	T4.1
Guztira Estimaturiko Orduak:		300 h	

2.2 Taula: Atazen denbora-estimazioak eta atazen arteko loturak.


2.2 irudian erakusten den GANTT kronogramak garapen eta esperimentazio prozesu iteratibo jarraitua islatzen du. Esperimentazioa (T4.1 eta 1.x-3.x probak) garapen teknikoarekin paraleloan txandakatu denez, proiektuaren bide kritiko iteratiboa honako sekuentzia honek osatu du.

$$T1.1 \longrightarrow T1.2 \longrightarrow T2.1 \longrightarrow T2.2 \longrightarrow T2.3 \longrightarrow T2.4 \longrightarrow T4.1 \longrightarrow T4.2 \quad (2.2)$$

2.3.1 Proiektuaren Bilakaera eta Kronologia

Proiektuaren garapena lau fase sekuentzial eta iteratiboetan igaro da.

2. PROIEKTUAREN KUDEAKETA ETA PLANIFIKAZIOA



2.2 Irudia: Proiektuaren GANTT kronograma eta garapen-esperimentazio iteratibo jarraitua.

- 1. Dokumentazioa eta Marko Esperimentalaren Finkatzea.** Hasieran artikuluko zientifikoak aztertu eta zuzendariarekin esperimentazio-markoa ezarri zen. Datuetan informazio-itzaletatik txertatzea definitu zen ezjakintasuna simulatzeko, funtzio sintetiko sinpleetatik MNIST eta CIFAR-10 irudietara igaroz.
- 2. Oinarrizko Arkitektura Modularra eta Klase Abstraktuak.** Lehenik oinarrizko klase abstraktuak garatu ziren (`BaseDataGenerator`, `BaseShadow`, `BaseClassifier`, `Splitter` eta orkestratzailea). Diseinu honek egitura nagusia aldatetik gabe mantentzea ahalbidetu du.
- 3. Lehenengo Esperimentuak (1.x) eta Kalitate-Probak.** 1.x esperimentuak arkitekturaren eta softwarearen baliozkotasuna egiaztatzeke erabili ziren, garatutako kodearen kalitate-proba gisa jokatuz.
- 4. Garapen Eskalatua eta Weka Datu Tabularrak.** Oinarri sendoarekin, koadernoaren ordenean modulu zehatzak garatu ziren. Azkenean, Weka datu tabularrekin lan egin ahal izan zen, PCA eta *k*-means *clustering* itzaletatik inplementatuz.

2.4 Arriskuen eta Desbideratzeen Analisia

Proiektuan zehar balizko desbideratzeak kudeatzeko, 2.3 taulan arrisku-matrizea definitu da.

ID	Arriskuaren Deskribapena	Prob.	Inpaktua	Prebentzio eta Erantzun Neurria
R1	Sare neuronalen entrenamendu-denbora luzeegiak konputazio-baliabide mugatuetan.	Ertaina	Altua	Azpi-multzo kontrolatuak, hazi finkoak eta MC Dropout laginketa optimizatua erabili.
R2	Datu-iturri ezberdinen arteko formatu-bateragarritasun eza (PyTorch, Scikit-learn, Weka).	Ertaina	Ertaina	Klase base abstraktuak (<code>BaseDataGenerator</code> , <code>BaseShadow</code>) eta interfaze bateratuak inplementatu.
R3	Web aplikazioaren Canvas-eko marrazkien zarata eta formatu desbideratzea.	Ertaina	Baxua	Irudien zentro-masaren bidezko zentratzea eta MNIST tamainako aurre-prozesamendua sartu.
R4	Hasierako software-azpiegituraren egonkortasun eza lehen faseetan.	Baxua	Altua	1.x esperimenduak balioztatze eta kalitate-proba gisa erabili garapen azkarra bermatzeko.

2.3 Taula: Arriskuen ebaluazio-matrizea eta kudeaketa-neurriak.

Oinarri Teorikoak eta Artearen Egoera

Informazio-itzalen detekzioa eta ikusi gabeko eremuetako ziurgabetasuna aztertzeko, probabilitate-teoriaren, Sare Bayesiarren eta neurketa-metriken oinarri formala finkatu behar da. Kapitulu honetan modulu nagusietan (`models.py`, `classifiers.py` eta `interpreter.py`) garatutako formulazio matematikoak aurkeztu eta deskribatzen dira.

3.1 Sare Neuronal Bayesiarrek eta Probabilitate Inferentzia

Sare neuronal konbentzionaletan parametro bakoitza balio eskalar finko bat da ($w \in \mathbb{R}$). Eredu hauek puntu bakar bateko estimazioa itzultzen dutenez, entrenamendueremutik kanpoko sarrerei erantzuteko garaian gehiegizko konfiantza erakusten dute. Sare Neuronal Bayesiarrek (BNN, ingelesez *Bayesian Neural Networks*) [2], aldiz, balio finkoen ordez probabilitate-banaketak esleitzen dizkiote parametro bakoitzari, 3.1 irudian adierazten denez.

Datu-sorta bat emanda $D = \{(x_i, y_i)\}_{i=1}^N$, Bayes-en teoremaren bidez parametroen ondorengo probabilitate-banaketa kalkulatu nahi da.


$$p(w \mid D) = \frac{p(D \mid w) p(w)}{p(D)} = \frac{p(D \mid w) p(w)}{\int p(D \mid w) p(w) dw} \quad (3.1)$$

Nolanahi ere, 3.1 ekuazioko izendatzaileko marjinalizazio-integrala konputazio-alki bideraezina da parametro ugariako sare sakonetan.

3.1.1 Bariaziozko inferentzia eta ELBO Froga Matematikoa

Integral hori zuzenean kalkulatzeko ezintasunari aurre egiteko, Bariaziozko inferentziaren teknika erabiltzen da. Hurbilketa honetan, benetako ondorengo banaketa

3. OINARRI TEORIKOAK ETA ARTEAREN EGOERA



3.1 Irudia: Sare neuronal konbentzionalen eta Sare Neuronal Bayesiarren arteko egiturazko konparazioa, pisu finko zein probabilistikoak adieraziz.

konplexua $p(w \mid D)$ familia analitiko sinpleago baten bidez $q_\theta(w)$ hurbiltzen da, normalean banaketa gaussiar independenteak adieraziz.

Bi banaketen arteko desberdintasuna minimizatzeko Kullback-Leibler, D_{KL} , desbideratzea erabiltzen da.

$$D_{\text{KL}}(q_\theta(w) \parallel p(w \mid D)) = \int q_\theta(w) \log \frac{q_\theta(w)}{p(w \mid D)} dw \quad (3.2)$$

Bayes-en teorema ($p(w \mid D) = \frac{p(x,y|w)}{p(x,y)}$) ordezkatzuz eta garapen algebraikoa eginez.

$$D_{\text{KL}}(q_\theta(w) \parallel p(w \mid D)) = \int q_\theta(w) \log \left(\frac{q_\theta(w) \cdot p(D)}{p(D \mid w) p(w)} \right) dw \quad (3.3)$$

Logaritmoaren propietateak erabiliz ($\log(a \cdot b/c) = \log a - \log c + \log b$).

$$D_{\text{KL}}(q_\theta(w) \parallel p(w \mid D)) = \int q_\theta(w) \left[\log q_\theta(w) - \log p(w) - \log p(D \mid w) + \log p(D) \right] dw \quad (3.4)$$

Jakinda $\int q_\theta(w) dw = 1$ dela eta itxaropen matematikoaren definizioa aplikatuz.

$$D_{\text{KL}}(q_\theta(w) \parallel p(w \mid D)) = \mathbb{E}_{q_\theta(w)}[\log q_\theta(w)] - \mathbb{E}_{q_\theta(w)}[\log p(w)] - \mathbb{E}_{q_\theta(w)}[\log p(D \mid w)] + \log p(D) \quad (3.5)$$

Urrats honetan, **Evidence Lower Bound**, ELBO, funtzioa definitzen da.

$$\mathcal{L}_{\text{ELBO}}(\theta) = \mathbb{E}_{q_\theta(w)}[\log p(D \mid w)] - D_{\text{KL}}(q_\theta(w) \parallel p(w)) \quad (3.6)$$

Ondorioz, KL desbideratzearen eta datuen froga-marjinalaren arteko erlazioa 3.7 ekuazioaren bidez finkatzen da.

$$\log p(D) = \mathcal{L}_{\text{ELBO}}(\theta) + D_{\text{KL}}(q_{\theta}(w) \parallel p(w \mid D)) \quad (3.7)$$

Datuen frogapena $\log p(D)$ konstantea denez θ parametroarekiko, $D_{\text{KL}}(q_{\theta}(w) \parallel p(w \mid D))$ minimizatzea eta 3.6 ekuazioko $\mathcal{L}_{\text{ELBO}}(\theta)$ maximizatzea guztiz baliokideak dira.

Deskonposizio eta ondorio matematiko honek funtsezko garrantzia du proiektuaren garapen teknikoan. Izan ere, Bayes-en teoremako izendatzailearen marjinalizazio bideraezina 3.6 ekuazioko optimizazio-funtzio bilakatzen du, `models.py` fitxategiko `BayesianLinear` geruzetan galeraren minimizazio konbentzional baten bidez entrenatzea ahalbidetuz. Garapen matematiko honek bi indar osagarri orekatzen ditu entrenamenduan: alde batetik, datuen bideragarritasuna maximizatzea ($\mathbb{E}_{q_{\theta}(w)}[\log p(D \mid w)]$), eta bestetik, KL desbideratzearen bidez pisuen banaketa aurretiaz ezarritako banaketatik gehiegi urruntzea zigortzea ($D_{\text{KL}}(q_{\theta}(w) \parallel p(w))$). Mekanismo honi esker, sareak ikusgaiko datuen ezaugarriak ikasteaz gain, pisuen bariantza eta ezjakintasuna egoki kodetzen ditu, informazio-itzaletan sarrera ezezagunak aurkezten direnean entropia altua eta bimodalitate garbia lortzeko oinarri matematiko sendoa ezarrituz.

3.1.2 Reparameterization Trick implementazioan

PyTorch bezalako esparru estandarrek ez dutenez berezko geruza bayesiarrik eskaintzen, `src/models.py` fitxategian `BayesianLinear` geruza zehatza inplementatu da `torch.nn.Module` oinarri hartuta. Entrenamenduan atzera-hedapena erabili ahal izateko, geruza honetan Kingma eta Welling [3] ikertzaileek garatutako eta Blundell et al. [2] autoreek sare probabilistikoetara egokitutako **Reparameterization Trick** teknika inplementatu da. Pisuak probabilitate-banaketatik zuzenean oinarritu ordez (eragiketa ez-deribagarria litzatekeena eta gradienteen igorpena etengo lukeena), ausazkotasuna $\epsilon \sim \mathcal{N}(0, I)$ zarata estandarrean isolatzen da.

$$w = \mu_w + \sigma_w \odot \epsilon, \quad \text{non} \quad \sigma_w = \log(1 + \exp(\rho_w)) \quad (3.8)$$

Mekanismo honen funtsezko balioa honako hau da: probabilitate-parametroak (μ_w batezbestekoa eta ρ_w bariantzaren kontrolatzailea) transformazio determinista deribagarri bilakatzen dira. 3.8 ekuazioari esker, PyTorch-eko `autograd` motoreak gradienteak μ_w eta ρ_w parametroekiko modu deterministan igortzea ahalbidetzen du, sarearen barne-bariantza eta ezjakintasuna gradiente-beherakadaren bidez era eraginkor eta egonkorrean ikastea bermatuz.

3.2 Multzokapen Probabilistikoak eta Hurbilketak

Sare Bayesiar puruen konputazio-kostu altua dela eta, ikasketa automatiko sakonean bi hurbilketa praktiko eta eraginkor gailendu dira.

3.2.1 Monte Carlo Dropout Hurbilketa

Gal eta Ghahramani ikertzaileek [4] frogatu zutenenez, sare neuronal arruntetako *dropout* teknika inferentzia-fasean ere aktibatuta mantentzen bada (kodeko `self.network.train()` deiaren bidez), prozesu bayesiar baten hurbilketa lortzen da.

Inferentzia egiterakoan lagin berbera T bider pasatzen da sarera ($n_{\text{iter}} = 50$), bakoitzean neurona-azpimultzo ezberdinak itzalita mantenduz. Batez besteko probabilitatea 3.9 ekuazioaren bidez kalkulatzen da.

$$\bar{p}_c(x) = \frac{1}{T} \sum_{t=1}^T \text{Softmax} \left(f^{(t)}(x) \right)_c \quad (3.9)$$

3.2.2 Deep Ensembles Metodologia

Lakshminarayanan et al. [5] ikertzaileek erakutsi dutenez, ziurgabetasuna kalibratzeko beste bide oso zehatz bat arkitektura bera duten M eredu ezberdin ausazko hasieraketarekin eta datu-azpimultzo ezberdinekin entrenatzea da (*Bagging*). `EnsembleClassifier` eta `EnsembleRegressor` moduluetan eredu ezberdinen arteko desadostasuna erabiltzen da bariantza neurtzeko.

3.2.3 Random Forest Ereduaren Bariantza Natiboa

Mentch eta O'Connell-en lanetan [6] zein Breiman-en jatorrizko lan seminalean [7] aztertu bezala, **Random Forest** eredia ausazko erabaki-zuhaitzen multzokapen estatistiko bat da. `RandomForestClassifierModel` inplementazioan, M zuhaitz bakoitzaren iragarpen-probabilitateak ($p_c^{(m)}(x)$) independenteki biltzen dira.

$$\bar{p}_c(x) = \frac{1}{M} \sum_{m=1}^M p_c^{(m)}(x) \quad (3.10)$$

Zuhaitz ezberdinen arteko desbideratze estandarrak eta bariantzak ziurgabetasunaren neurri natiboa eskaintzen dute.

3.2.4 Erregresio-metrikak eta Batez Besteko Errore Koadratikoa

Erregresio-ereduen doitasun orokorra eta informazio-itzaletan duten desbideratzea kuantifikatzeko, **Batez Besteko Errore Koadratikoa** (MSE, *Mean Squared Error*) erabiltzen da neurketa-metrika nagusi gisa.

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (3.11)$$

Ekuazio horretan, y_i benetako balioa da eta $\hat{y}_i$ ereduak egindako iragarpena. Metrika honek zigor koadratikoa ezartzen die akats handiei, eta bereziki erabilgarria da eredu batek muturreko itzaletan kurbadura jarraitu ezinik sortzen dituen desbideratze larriak detektatzeko.

3.3 Ziurgabetasunaren Estimazioa eta Entropia

Ziurgabetasun probabilitistikoa bi jatorri nagusitan banatzen da [8].

- **Ausazko Ziurgabetasuna.** Datuen berezko zaratak sortua eta datu gehiagorekin murriztu ezin dena.
- **Ziurgabetasun Epistemikoa.** Ereduaren ezjakintasunak edo informazio-itzaletan kokatzeak sortua eta ezagutza gehiagorekin murrizgarria dena.

3.3.1 Softmax Funtzioaren Mugak eta *Energy Score*

Liu et al. [9] eta Hendrycks & Gimpel [10, 11] ikertzaileek erakutsi dutenez, sare neuronal arruntek itzaldutako datu berrien aurrean erakusten duten gehiegizko konfiantza Softmax funtzioaren propietate normalizatzaileari dagokio.

$$\text{Softmax}(f(x))_c = \frac{\exp(f_c(x))}{\sum_{j=1}^K \exp(f_j(x))} \quad (3.12)$$

Softmax funtzioak *logit*-en balio absolutua galdu egiten du probabilitateak lera batzera behartzean. Muga hau gainditzeko, *energy-score* formulazioa 3.13 proposatu izan da literaturan.

$$E(x; f) = -T \cdot \log \sum_{j=1}^K \exp\left(\frac{f_j(x)}{T}\right) \quad (3.13)$$

Nahiz eta *energy-score* formulazioa literaturan Softmax funtzioaren gehiegizko konfiantza arintzeko alternatiba teoriko gisa erabili, proiektuaren garapen teknikoan eta software-arkitekturan **Shannon-en entropia** hautatu dugu neurketa nagusi eta unibertsatu gisa. Aukera honek eredu mota guztiak esparru probabilitistiko bakarraren pean neurtzea eta **UncertaintyInterpreter** moduluan muga estatistikoko ez-parametrikokoak modu homogeneo eta interpretagarrian finkatzea ahalbidetu du.

3.3.2 Shannon Entropiaren Banaketa Bimodala

Eredu probabilitistiko batek klase anitzeko sailkapenean adierazten duen ziurgabetasun osoa kuantifikatzeko, `classifiers.py` moduluan **Shannon-en entropia** [12] erabiltzen da.

$$H(p) = - \sum_{c=1}^K \bar{p}_c \log(\bar{p}_c + 10^{-10}) \quad (3.14)$$


Aipagarria da 3.14 ekuazioko $+10^{-10}$ balio infinitesimalaren agerpena. Konputazio zientifikoa eta `src/classifiers.py` nahiz `src/ensemble.py` moduluetak inplementazio errealean, osagai hau gehitu da zenbakizko egonkortasuna bermatzerakoan. Matematikoki $\lim_{p \rightarrow 0^+} p \log(p) = 0$ den arren, ingurune informatikoetan probabilitate zero baten logaritmoa kalkulatzeko zenbakizko mugagabetasuna sortuko luke. $+10^{-10}$

3. OINARRI TEORIKOAK ETA ARTEAREN EGOERA

balioa gehitzeari esker, $0 \log(0) = 0$ baldintza teorikoa konputazionalki bermatzen da eta eragiketa ez-baliozkoak erabat ekiditen dira.

Eredu probabilista kalibratu batean, Shannon-en entropiaren dentsitate-funtzioak Kernel Density Estimation, KDE, bidez irudikatzean banaketa bimodala erakutsi behar du bi populazio ezberdinen artean (3.2 irudia).

1. **Tontor Urdina, Ikusgaiko Test Datuak.** Eredua ikusitako informazioaz ziur dagoenez, entropiaren banaketa zero inguruko balioetan kontzentratzen da ($H(p) \approx 0$).
2. **Tontor Gorria, Itzaldutako Test Datuak.** Ereduak bere ezjakintasuna aitortzean, klase guztien arteko probabilitate uniforme ematen du, entropia balio altuetan kontzentratuz ($H(p) \approx \log K$).



3.2 Irudia: Shannon entropiaren dentsitate-banaketak KDE bidez: (a) emaitza onak ere du kalibratu batean, bi tontorrek ongi bereizita eta τ^* muga finkatuz ziurtasuna zehaztasunez detektatuz; (b) emaitza kaxkarrak gainezarpenarekin, ere duak itzaletan gehiegizko konfiantza duenean ziurtasuna bereiztea galaraziz.

3.4 Egiturazko Balioztatzea eta Informazio-itzalen Detekzioa

Informazio-itzalak era objektibo batean hautemateko bi bide metodologiko nagusi ezarri dira software-azpiegituran.

3.4.1 Conformal Prediction eta Muga Estatistikoak

Angelopoulos eta Bates-en [13] *Conformal Prediction* esparruak erakusten duenez, muga estatistiko ez-parametrikokoak finkatzea da biderik seguruena datu ezagunak eta informazio-itzalekoak bereizteko. Printzipio honi jarraituz garatu da arkitektura *UncertaintyInterpreter* modulua (*interpreter.py*), entropiaren banaketan muga optimoa τ^* bilatuz.

$$x \in \text{Informazio-Itzala} \iff H(p(x)) \geq \tau^* \quad (3.15)$$

3.4.2 Kluster bidezko Balioztatze Gurutzatua

Roberts et al. [14] lanak erakusten duenez, K-Fold balioztatze gurutzatu arruntak batez besteko portaera orokorra modu errealistan islatzen badu ere, ezaugarri-espazioan hutsuneak daudenean ez du erakusten ereduak eremu ezezagun horietan duen erresilientzia. Informazio-itzaletan horiek artifizialki simulatzeko, arkitekturako `ClosestClusterShadow` eta `ClusterSplitter` moduluetan (`shadows.py`, `splitter.py`) PCA dimentsio-murrizketa eta k -means zentroide isolatzea inplementatu dira.



Garapen Tresnak eta Ingurune Teknologikoa

Proiektu honen implementazioa eta analisia aurrera eramateko, datuen zientzian eta ikasketa automatikoan estandarrak diren hainbat teknologia eta liburutegi erabili dira. Garapen osoa **Python 3** lengoaian oinarritu da, bere ekosistemak eskaintzen dituen erraztasunengatik eta komunitatearen babesagatik.

- **NumPy** eta **Pandas**. Matrizeen eragiketa konplexuak egiteko, datu-egiturak kudeatzeko eta esperimentuetako informazioa formatu tabularrean antolatzeko erabili dira.
- **PyTorch** [15]. Sare neuronal sakonak eta Monte Carlo Dropout arkitekturak eraikitze, entrenatzeko eta inferentzia probabilistikoak exekutzeko erabili den esparru nagusia.
- **Scikit-learn** [16]. Ikasketa automatikoko eredu tradizionalak, hala nola Random Forest eta Ensemble ereduak, implementatzeko eta datuak ebaluatzeko tresna nagusia izan da.
- **Weka** [17]. Datu-base tabularrak kargatzeko eta kluster bidezko OOD esperimentuak balioztatzeko erabilgarria.
- **SciPy**. Entropiaren kalkulu matematikoak eta probabilitate-banaketen analisia egiteko erabili da.
- **Flask** eta **HTML5 Canvas**. Denbora errealeko inferentzia probabilistikoa, OOD alerta-seinaleak eta ikasketa jarraitua bistaratzeko web aplikazio interaktiboa eraikitze erabili den teknologia.

Emaitzen azterketa bisuala egiteko, **Matplotlib** eta **Seaborn** erabili dira. Hauek aukera eman dute banaketa estatistikoak, ziurgabetasun-mailak eta itzaldutako datuen eraginak argi eta garbi irudikatzeko.

4.1 Garapen Ingurunea


Kodearen garapena moduluetan banatu den arren, esperimentuen exekuzioa, ebaluazioa eta emaitzen jarraipena **Jupyter Notebooks** bitartez kudeatu da. Ingurune honek iterazio azkarrak egiteko eta prozesu analitikoa modu interaktiboan dokumentatzeko aukera ezin hobea eskaini du. Software-arkitektura instalatzeko, liburutegien dependentziak kudeatzeko eta koadernoak zein web aplikazioa lokalki exekutatzeke jarraibide tekniko zehatzak [B](#) eranskineko Erabiltzailearen eta Inplementazioaren Manualean biltzen dira.

Diseinua eta Arkitektura

Proiektu honen software-arkitektura modularra, garbia eta zabalgarria izateko diseinatu da, Ikasketa Automatikoko eta Ikasketa Sakoneko esperimentu guztiak ingurune bera erabiliz exekutatu ahal izateko. Softwarearen egitura eta moduluen arteko harremanak objektuei bideratutako programazioaren printzipio egokietan oinarritzen dira, polimorfismoa, heredapena eta abstrakzio-maila altuak lehenetsiz.

5.1 Arkitektura Modularraren Ikuspegi Orokorra


Sistemak hiru zutabe nagusi ditu: datuen kudeaketa eta itzalen injekzioa, eredu probabilitistikoen azpiegitura, eta ebaluazio zein interpretaziorako orkestratzailea. Trebatze-eta ebaluazio-fluxu osoa 5.1 irudian ikus daiteke, osagai bakoitzaren eginkizuna eta haien arteko loturak argi adieraziz.



5.1 Irudia: Sistemaren arkitektura modularraren prozesu-fluxu osoa.

5.2 UML Klase-Diagrama eta Interfazeak

Sistemaren klase nagusiak, heredapen-erlazioak eta interfaze polimorfikoak 5.2 irudiko UML diagraman biltzen dira. Bertan moduluen arteko mendekotasunak eta abstrakzio-mailak finkatzen dira: datu-sortzaileak (**BaseDataGenerator**), itzalak (**BaseShadow**), sailkatzaile probabilitistikoak (**ProbabilisticClassifierModel**), eta orkestratzailea (**ClassificationOrchestrator**).



5.2 Irudia: Sistemaren UML Klase-Diagrama polimorfikoa eta egiturazkoa.

5.3 Sekuentzia-Diagrama eta Exekuzio-Fluxua


Sistemaren moduluen arteko mezu-trukea eta exekuzio-fluxu denborala adierazteko, 5.3 irudian UML Sekuentzia-Diagrama erakusten da. Diagrama honek esperimentu baten bizi-ziklo osoa irudikatzen du, `orchestrator.run()` metodoaren dei bakar batetik abiatuta.

5.4 Datuen Kudeaketa eta Polimorfismoa

Sistemak jorratzen duen arazo nagusietako bat mota eta dimentsio ezberdinetako datu-multzoak, sintetikoak, irudiak zein datu-base tabularrak, eredu berdinen bitartez ebaluatze beharra da. Arazo hau konpontzeko, `generators.py` moduluak diseinupatroi argi bat jarraitzen du, polimorfismoan eta oinordetzan oinarrituta.

5.4.1 Interfaze Estandarra

Datu sortzaile guztiak klase abstraktu nagusi batetik eratorriak dira: **BaseDataGenerator**. Klase honek egiturazko betebeharrak ezartzen ditu: `generate` metodoa.



5.3 Irudia: UML Sekuentzia-Diagrama mezu-trukaketaren bizi-ziklo garbia irudikatuz.

Sortzaile espezifiko orok metodo hau implementatu behar du hiru parametro nagusirekin: lagin kopurua (`n_samples`), balioen tartea (`x_range`) eta zarataren kudeaketarako estrategia (`noise_strategy`). Horrela, arkitekturako gainerako moduluak (`orchestrator.py` adibidez) ez dute zertan datu motaren barne-egitura ezagutu, interfaze estandar honekin soilik komunikatzen baitira.

5.4.2 Datu Sintetikoaren Sorkuntza

Arazo sintetikoetan, datuen sorkuntza `Math2DGenerator` klasearen bidez egiten da. Sortzaile honek funtzio matematiko zehatz bat jasotzen du sarrera gisa. Lehenik, zorizko X balioak sortzen ditu zehaztutako tartearen barruan banaketa uniforme bat erabiliz, `np.random.uniform`. Ondoren, emandako funtzio matematikoa aplikatzen du Y garbi bat lortzeko. Azkenik, errealitateko ziurgabetasuna simulatzeko asmoz, zehaztutako zarata-estrategia, hala nola, `AbsoluteGaussianNoise`, aplikatzen dio Y horri. Honela, erduek patroiak ezin hobeto ikastea zailtzen duten inperfekzio naturalak sortzen dira.

5.4.3 Irudien Prozesamendua eta Estandarizazioa

Ikasketa automatiko klasikoko erduek, Random Forest esaterako, bektore unidimensionalekin lan egiten dute, eta ez matrize edo tentsore multidimentsionalekin. Hori dela eta, `MNISTGenerator` eta `CIFAR10Generator` klaseek funtsezko lan bat egiten dute: irudiak estandarizatzea eta berdintzea, komunitate zientifikoan ezarritako prozesamendu-estandarrak jarraituz.

- **MNISTGenerator.** LeCun et al. [18] autoreen estandarrari jarraituz, eskuz idatzitako zenbakien datu-basea `torchvision` bidez kargatzen da. Klase honek

28×28 tamainako pixel-matrizeak 784 elementuko bektore jarraitu bilakatzen ditu, eta pixel bakoitzaren intentsitatea $[0, 1]$ tartean kokatuz normalizatzen du. Irudien egitura zentratuari esker, dimentsio-berdintze honek berezko topologia gutxi eraldatzen du eta zehaztasun altua mantentzen du.

- **CIFAR10Generator.** Krizhevsky-ren [19] datu-basea konplexuagoa da, 3 kolore-kanal, RGB, dituzten 32×32 irudiz osatuta dagoelako. Klase honek irudi hauek 3072 elementuko bektore unidimentsional bilakatzen ditu ($32 \times 32 \times 3$). Prozesu honetan, kolore-kanal bakoitza independenteki normalizatzen da, kanal bakoitzaren batezbestekoa eta desbideratze estandarra erabiliz, 0.5 balioarekin ardatz bakoitzean, sarrerak $[-1, 1]$ tartean kokatzeko.

Ohar garrantzitsu bat egin behar da: irudien espazio-egitura bektore unidimentsionaletara bihurtzeak eragina dauka eredu klasikoaren sailkapen-zehaztasunean, bereziki CIFAR-10en, konboluzio-sareen tokiko ezaugarriak galtzen direlako. Halere, azterketa honen helburu nagusia ez denez sailkapen absolutua hobetzea baizik eta ziurgabetasunaren estimazioa eta OOD detekzioa aztertzea, 6. kapituluko esperimentuetan ikusiko da Random Forest-ek eta Ensemble eredu probabilitistikoek beren sendoera eta bimodalitate bikoitza ezin hobeto mantentzen dutela informazio-itzalen aurrean.

5.4.4 Datu-Base Tabularrak eta Weka Iragazkiak

Hirugarren blokean, Weka datu-base tabularrekin lan egiteko, `WekaDataGenerator` garatu da. Klase honek Weka formatuko ARFF fitxategiak irakurtzen ditu. Datu-mota hauetan ezaugarri zenbakidunak zein kategorikoak nahasten direnez, klaseak barne-prozesamendua egiten du: ezaugarri kategorikoak zenbakizko balioetan kodetzen ditu eta aldagai jarraituak normalizatzen ditu, *z-score* estandarizazioa aplikatuz.

5.5 Informazio-Itzalen Injekzioa, `shadows.py`

Sistemaren ezinbesteko beste zutabe bat `shadows.py` moduluak osatzen du. Modulu honen xedea datu-multzoetan informazio-itzalak artifizialki sortzea da, ebaluazio-fasean ereduak ikusi gabeko eremuen aurrean duten portaera eta ezjakintasuna aztertu ahal izateko. Datuen sorkuntzan gertatzen den moduan, `BaseShadow` klase abstraktuak interfaze komuna ezartzen du modulu guztientzat, `apply` metodoaren bidez.

5.5.1 Datu Sintetikoetako Itzalak

Datu unidimentsional eta bidimentsionalen kasuan, espazio geometrikoa ebakitzen duten klaseak inplementatu dira. Hauen funtzioa datuen eremu zehatzak ezabatzea da. Aipagarria da itzal hauek ez direla ausaz aukeratzen, estrategikoki kokatzen dira informazio-karga handiena duten eremuak hartzeko, hala nola funtzio sinusoidal baten tontorrak edo okerdura-aldatze puntu nagusiak. Esaterako, X ardatzeko tarte gako jakin bateko lagin guztiak ezkuta daitezke. Honela, ereduak tarte horretako egiturazko informaziorik gabe entrenatuko dira, eta ebaluazio-fasean soilik erakutsiko

zaizkie itzalpeko datu horiek, ereduaren interpolazio zein estrapolazio gaitasuna, baita beren ziurgabetasunaren neurketa ere, zorroztasunez probatzeko.

5.5.2 Irudietako Itzalak

Irudien kasuan, MNIST eta CIFAR-10 datu-baseekin lan egiteko, itzalak aplikatzeko estrategia semantikoak garatu dira.

- **Klaseen ezkutatzea.** Klase zehatz baten bidez, kategoria osoak, adibidez zenbaki jakin batzuk edo animalia mota batzuk, erabat kentzen dira entrenamendutik. Gero, ebaluazioan klase horiek aurkeztean, ereduak nolako probabilitate-banaketa itzultzen duen behatzen da, berez ezagutzen ez duen kontzeptu baten aurrean dagoela jabetzen den ala ez aztertuz.
- **Antzekotasunean oinarritutako itzalak.** Esperimentu batzuetan, elkarren artean antz handia duten klaseak ezkututzen dira, ereduak ezaugarri bisual zehatzagoak ikastera behartuz.

5.5.3 Datu Tabularren Itzalak

Datu-base tabularretan ezaugarri multidimentsionalak nahasten direnez, itzalak injektatzeko `ClosestClusterShadow` klasea garatu da `src/shadows.py` fitxategian. Inplementazio hau software-diseinuaren hiru zutabe nagusietan oinarritzen da:

- **Polimorfismoa.** `ClosestClusterShadow` klaseak `BaseShadow` hedatzen du. Diseinu polimorfiko honi esker, `ClassificationOrchestrator` eta `ClusterSplitter` interfaze beraren bidez komunikatzen dira, kluster itzala trukagarri bihurtuz.
- **Multzokatu Automatikoa eta Tuninga.** Moduluak `sklearn.cluster.KMeans` bidez ezaugarri-espazioaren azterketa egiten du. Kluster kopuru ideala hautatzeko, $K \in [5, 10]$ tartea aztertzen da eta `silhouette_score` neurketa maximizatzen duten zentroideak gordetzen dira.
- **Zentroide Zentralaren Identifikazioa eta Iragaztea.** Behin klusterrak finkatuta, zentroideen arteko distantzia-matrizea kalkulatzen da. Gainerako zentroide guztiekiko distantzia-baturarik txikiena duena, hau da, datu-multzoaren erdi-erdian dagoen kluster zentralarena, hautatzen da. Kluster zentral horretako lagin guztiak ezkutatu egiten dira, informazio-dentsitate handieneko eremuan informazio-itzal errealista bat sortuz.

5.6 Datuen Banaketa Egituratua, `splitter.py`

Ikasketa automatikoko prozesu konbentzionaletan, datuak zoriz banatzen dira entrenamendu eta test multzoetan. Alabaina, ausazko zatiketa arruntek sarrerako datuak espazio osoan zehar nahasten dituztenez, test multzoko adibideak entrenamenduen oso antzekoak izaten dira. Ondorioz, ausazko banaketek ez dituzte agerian uzten ereduak informazio-itzalen aurrean dituzten ezjakintasunak edo gaitasun-mugak.

Gabezia horri aurre egiteko, `splitter.py` moduluak informazio-itzalak kontuan hartzen dituzten zatiketa-estrategiak eskaintzen ditu. Modulu honen funtsezko zeregina `shadows.py` fitxategian definitutako iragazkiak aplikatzea da, datu-multzo osoa hiru azpi-multzo independente hauetan banatuz.

- **Ikusgaiko Entrenamendu Datuak.** Informazio-itzaletik kanpo gelditzen diren laginak dira, eta eredia soilik datu hauen bitartez entrenatzen da.
- **Ikusgaiko Test Datuak.** Entrenamenduko eremu bereko test-laginak dira, ereduak ohiko ingurune ezagunean duen zehaztasuna neurtzeko balio dutenak.
- **Itzaldutako Test Datuak.** Informazio-itzalaren barruan erabat isolatutako laginak dira, eta ebaluazio-fasean soilik erabiltzen dira ereduaren ziurgabetasunaren estimazioa zein itzaldutako datuen detekzioa zorroztasunez egiaztatzeko.

Halaber, `GapSplitter` eta `ClusterSplitter` bezalako klaseei esker, banaketa hauek zirrikituaren edo kluster geografikoen arabera egituratzen dira. Prozesu honetan beti erabiltzen da hazi finko bat, esperimenteren exekuzioak guztiz konparagarriak eta errepikagarriak izan daitezkeen.

5.7 Ikasketa Ereduak `models.py`, `classifiers.py` eta `ensemble.py` Fitxategietan

5.7.1 Arkitektura Matematikoak, `models.py`

Fitxategi honetan algoritmoen egitura gordina eta sare neuronalen arkitekturak implementatzen dira. Esperimenteren izan duten garrantziaren eta erabileraren arabera, barneko ereduak honela sailkatzen dira (eredu probabilistiko bakoitzaren konfigurazio eta hiperparametro estandarrek [D](#) eranskinen [D.1](#) taulan kontsulta daitezke).

- **Oinarritzko Ereduak.** Datu sintetikoekin, hau da, 1D eta 2D funtzio matematikoekin, egindako hasierako esperimenteren soilik erabili dira. Talde honetan sartzen dira erregresio lineala, erregresio polinomikoa eta oinarritzko Perzeptroi Anitzak, MLP. Eredu hauen helburua sistemaren oinarritzko funtzionamendua frogatzea izan da, eta azkar erakutsi dute beren muga arazo konplexuagoetara igarotzean. Horregatik, ez dute pisu handirik izan ondorengo faseetan.
- **Dropout bidezko Sare Neuronalak.** Eredu hauek garrantzi handia izan dute proiektuan, bereziki MNIST eta CIFAR-10 irudien sailkapenean. Sarea entrenatzerakoan zein inferentzian, Dropout geruzek neuronen aktibazioak ausaz itzaltzen dituzte ($p = 0.30$). Arkitekturari dagokionez, Dropout geruzak ez dira sareko maila guztietan bereizi gabe aplikatu:
 - Sare trinkoetan (MLP, MNIST eta erregresiorako erabiliak), ezkutuko geruza bakoitzaren atzetik txertatu da Dropout-a (aktibazio ez-linealaren ondoren), baina irteerako azken geruza linealari ez zaio aplikatu, logit-en estimazio zuzena ez desitxuratzeko.

- Sare konboluzionalean (CNN, CIFAR-10erako erabilia), ezaugarri-erazule espazialetan (bloke konboluzionaletan) ez da dropout-ik erabili; horren orde, amaierako sailkapen-buru trinkoan (*fully connected* geruzaren ostean) kokatu da, azken irteera-klaseen aurretik.
- **Sare Neuronal Bayesiarrak (BNN).** Hauek dira ziurgabetasuna neurtzeko proiektuaren apustu nagusietako bat. Ohiko pisu finkoen orde, sare Bayesiarrak ekuazioetako parametro bakoitza probabilitate-banaketa baten bidez adierazten dute. Funtsezko osagai hau `src/models.py` fitxategian inplementatu da `BayesianLinear` geruzen bidez, Blundell et al. [2] autoreen formulazio teoriarri eta Kingma eta Welling [3] ikertzaileen *Reparameterization Trick* mekanismoari zorrotz jarraituz. Itzaldutako datuak detektatzeko orduan sekulako garrantzia izan dute, sistemari zuzenean ez dakit erantzuteko eta entropia altuko probabilitate-esparruak itzultzeko gaitasuna ematen diotelako.

5.7.2 Sailkatzaileen Interfaze-Egokitzapena, `classifiers.py`

Eredu matematikoak ebaluazio estandarrera egokitzeko, `classifiers.py` moduluak abstrakzio-geruza bat eraikitzen du. Diseinu honi esker, eredu klasikoak zein sare neuronalak `Scikit-learn` liburutegiaren interfaze bateratura moldatzen dira, haien arteko konparazio zuzena eta gardena ahalbidetuz. Barnean hartzen dituen klase nagusiak hauek dira:

- **PyTorch Bilgarria (`SklearnPyTorchClassifier`).** Sare neuronal estandarrek eta Bayesiarrak entrenatzeko eta ebaluatzeko erabiltzen da. Klase honek barnean kudeatzen ditu iterazioak, optimizatzaileak eta galeraren funtzioak, ikasketa prozesua orkestratzailearentzat erabat garden bihurtuz.
- **Eredu Klasikoen Egokitzaileak (`RandomForestClassifier`).** `Scikit-learn`-eko eredu tradizionalak zuzenean integratzen dira. Eredu hauek, *bagging* teknika erabiltzen dutenez, zuhaitz anitzen arteko bariantza neurtuz lor dezakete ziurgabetasunaren inguruko informazioa.
- **Monte Carlo Dropout (`MCDropoutClassifier`).** Dropout sarea ebaluazio-fasean eta inferentzian aktibatuta mantentzen du. Datu bera hainbat aldiz pasatzen da saretik, eta aldi bakoitzean konexio ezberdinak itzalita daudenez, iragarpen desberdinak lortzen dira. Iragarpen hauen arteko entropia kalkulatu, ereduaren ziurgabetasun-maila zehatz-mehatz lor daiteke. Irudien itzaldutako datuen detekzioan ezinbestekoa izan da.

5.7.3 Ereduen Bateratzea, `ensemble.py`

Esperimentuek aurrera egin ahala, bereziki MNIST datu-basearekin, arazo argi bat azaleratu zen: eredu batzuek ziurgabetasun handiegia erakusten zuten, `Random Forest`-aren kasuan datu ezagunetan ere entropia altua emanez, Sare Neuronalek aldiz, konfiantza larregi, itzaldutako datuetan entropia txikiegia emanez edo gehiegizko konfiantza agertuz. Bi joera kontrajarri hauek konpontzeko sortu zen `ensemble.py`.

- **Ensemble Sailkatzailea `EnsembleClassifier`.** Klase honek ez du eredu berri bat sortzen, baizik eta lehendik dauden hainbat eredu probabilistiko, adibidez Random Forest eta MC Dropout Sare Neuronalak, multzokatu eta bateratzen ditu probabilitate banaketen batezbestekoa eginez. Iragarpen garaian, eredu guztien irteerak konbinatzen dira. Ikuspegi honek itzaldutako datuen detekzioa nabarmen zorrotzu du: ereduak adostasuna dutenean entropia txikia lortzen da, ezagutzen duten informazioan zehaztasuna bermatuz, eta datu ezezagunen aurrean, ereduaren arteko desadostasunak bariantza eta entropia handia sortzen du.
- **Ensemble Erregresorea (`EnsembleRegressor`).** Erregresioan, Bariantza Osoaren legea aplikatzen da eredu ezberdinen iragarpenak eta bariantzak bateratzeko.

$$\text{Var}_{total} = E[\text{Var}(Y | M)] + \text{Var}(E[Y | M]) \quad (5.1)$$

Formula honek bi ziurgabetasun motak kalkulatzeko ditu: eredu bakoitzaren barne-bariantzen batezbestekoa, hots, ziurgabetasun aleatorikoa, eta eredu ezberdinen iragarpenen arteko bariantza, hau da, ziurgabetasun epistemikoa edo eredu arteko desadostasuna.

5.8 Sistemaren Bihotza, Orkestratzailea

`orchestrator.py` modulua proiektuaren ardatz nagusia da. Eredu edo datu-sortzaile zehatz bat izan beharrean, osagai guztiak modu koherentean bateratzeaz eta prozesu konplexuak automatizatzeaz arduratzen da. Funtsean, aurretik aipatu diren pieza guztiak orkestratzen dituen klasea da, eta hortik datorkio izena.

Adibideek erakusten duten moduan, `orchestrator.py` fitxategiak edozein modulu trukatzeko ahalbidetzen du arazoaren eskakizunen arabera. Bukaerako helburua erregresioa ala sailkapena izan, edota neurgailua bariantza ala entropia izan, interfazeak egitura estandarra jarraitzen du, proiektu osoari ikerketa-ingurune tinko eta aldi berean malgua esleitzen diolarik.

5.9 Osagarri Gehigarriak, `noise.py`, `visualization.py` eta `interpreter.py`

Proiektuaren arkitektura nagusia eta ebaluazio-prozesuaren nukleoa deskribatu ondoren, badaude beste hiru modulu zehatz esperimentazio eta analisi fasean funtsezkoak izan direnak.

5.9.1 Zarataren Injekzioa, `noise.py`

Modulu hau txikia baina garrantzitsua da datu sintetikoen sorkuntzan. Bere funtzio nagusia errealitateko inperfekzioak simulatzeko da, seinale garbiei, 2D funtzio matematikoak esaterako, zarata gehituz. Estrategia desberdinak implementatzen ditu, hala nola zarata gaussiar absolutua edo erlatiboa, sistemak ereduak egoera errealistagoetan ebaluatzeko aukera izan dezan.

5.9.2 Emaizten Bistaratzeta, `visualization.py`

`visualization.py` modulua ezinbestekoa izan da esperimentuen emaitzak bistaz interpretatzeko. Modulu honek barne hartzen dituen funtzioen bidez hiru grafiko mota nagusi sortzen dira.

- **2D Funtzioen Irudikapena.** Datu sintetikoaren esperimenduetan kurben doikuntza eta eredu probabilistikoen ezjakintasun-banda, $\pm 2\sigma$ eremuan, erakusten ditu, zirriketako eremuan banda zabaltzen dela egiaztatuz.
- **Entropiaren Dentsitate Funtzioak.** Sailkapen arazoetan, bereziki MNIST eta CIFAR-10 irudiekin lanean, KDE dentsitate-grafikoak sortzen dira, hau da, Tontor Urdina ikusgai diren datuentzat eta Tontor Gorria itzaldutako datuentzat. Bi tontorren arteko bereizketa bisuala ereduaren itzaldutako datuen detekzio-kalitatearen adierazle nagusia da.
- **WEKA PCA Bistaratzeta `plot_weka_pca` Bidez.** Datu-base tabular konplexuetan, 2D PCA transformazioa erabiliz PC1 eta PC2 ardatzetan Train, Test Visible eta Test Shadow kluster topologiko gisa bistaratzen dira.

5.9.3 Itzaldutako Datuen Detektatzailea, `interpreter.py`

`UncertaintyInterpreter` klaseak bi tontorren entropia banaketaren bereizketa kualitatiboa neurketa eta muga objektibo batean bihurtzen du. Modulu honek honako zeregin hauek garatzen ditu.

1. Ikusgaiko datuei eta itzaldutako datuei etiketak esleitzen dizkie: $y_i = 0$ datu ezagunentzat eta $y_j = 1$ informazio-itzaleko OOD datuentzat.
2. Entropiaren barruti osoan 100 muga kandidatu τ (threshold delakoa) aztertzen ditu `np.linspace` bidez.
3. Bi taldeak gehien zehaztasunez bereizten dituen τ^* muga optimoa hautatzen du, $\hat{y} = \mathbb{I}(H(p) > \tau)$ sailkapen bitarra erabiliz.
4. Itzaldutako datuen OOD detekzio-zehaztasun osoa kalkulatzeko du `evaluate` metodoaren bidez, 5.2 formulazio matematiko formala jarraituz.

$$\text{OOD Detekzio Acc}(\tau^*) = \frac{\sum_{i=1}^{N_{\text{Known}}} \mathbb{I}(H(p_i) \leq \tau^*) + \sum_{j=1}^{N_{\text{Shadow}}} \mathbb{I}(H(p_j) > \tau^*)}{N_{\text{Known}} + N_{\text{Shadow}}} \quad (5.2)$$

Horrela, entropia-tontorrak aski bereizita daudenean, interpretatzaileak %100etik gertuko itzaldutako datuen detekzio-zehaztasuna egiaztatzen du, eta tontorrak nahasten direnean gehiegizko konfiantzako kasuetan, zehaztasunaren jaitsiera kuantifikatzen du.

5.10 Aplikazio Interaktiboa eta Ikasketa Jarraitua

Diseinatutako arkitektura modularren azken helburua ez da soilik koaderno zientifikoetan azterketa estatistikoak egitea, baizik eta eredu probabilistikoen eta ziurgabetasunaren kudeaketaren ahalmena aplikazio praktiko interaktibo batean erakustea. Horretarako, `src/3.1.4_karaktereen_web_aplikazioa` direktorioan web aplikazio bat garatu da, Flask zerbitzariaren eta HTML5 Canvas teknologiaren bidez (tresna honen instalazio- eta erabilera-gida [B](#) eranskineko Erabiltzailearen Manualean biltzen da).

Aplikazio honen funtzionamendua hiru zutabe nagusitan oinarritzen da.

1. **Canvas Interaktiboa eta Irudien Aurre-prozesamendua.** Erabiltzaileak pantailan eskuz marraztutako karakterea jaso, gris-mailara bihurtu, kontrastea inbertitu, zentro-masaren arabera zentratu eta 28×28 tamainako 784 elementuko bektore batera bihurtzen da, MNIST datu-basearen formatu estandarrarekin guztiz bateragarri eginez.
2. **Denbora Errealeko Inferentzia eta OOD Detekzioa.** Erabiltzaileak marraztutako lagin bakoitzaren aurrean, Ensemble ereduak sailkapen-probabilitateak eta Shannon-en entropia $H(p)$ kalkulatzeko dituzte. Ondoren, **Uncertainty Interpreter** modulua erabiliz, aplikazioak muga optimoa aplikatzen du: entropia baxua bada ($H \leq \tau^*$), klase ezagunaren aurreikuspena eta konfiantza erakusten dira, entropia altua bada ($H > \tau^*$), aplikazioak seinale gorria pizten du informazio-itzala eta ezezaguna den karakterea detektatu duela jakinaraziz.
3. **Ikasketa Jarraitua eta Ereduen Genealogia.** Aplikazioak erabiltzaileari aukera ematen dio marraztutako karaktere ezezagunei etiketa berriak esleitzeko eta `/train_new_class` bidez Ensemble ereduak denbora errealean berriro entrenatzeko. Ereduen bertsio-arbola bat kudeatzen da (v1, v2 bertsioak eta metadatuak JSON fitxategietan bilduz), ereduak gaitasun berriak modu gehikorrean ikas ditzan ziurgabetasuna mantenduz.

Aipatzekoa da web aplikazioaren *frontend*-aren inplementazioa, HTML5 Canvas interfazea, CSS3 estilo-sistema eta JavaScript logika, Hizkuntza Eredu Handien, LLM, bidezko azelerazio eta prototipatu bidez eraiki dela. Horri esker, software-ingeniaritzaren aldetik interfazearen kode osagarrian denbora gutxiago bideratu ahal izan da, ahalegin nagusia eta dedikazio zientifikoa proiektuan bertan dauden oinarritzko osagaietan bideratuz: eredu probabilistikoetan, informazio-itzal sintetiko zein tabularren sorkuntzan eta **UncertaintyInterpreter** moduluan.

Esperimentuak eta Emaitzak

Kapitulu honetan memoria osoan zehar garatutako software-arkitekturarekin eta eredu probabilistikoekin lortutako emaitza enpiriko zehatzak aurkezten dira. Gauzaturako hogeiki koaderno esperimentalen inbentario osoa [C](#) eranskinen [C.1](#) taulan biltzen da, eta eredu bakoitzean erabilitako hiperparametro estandarrak [D](#) eranskinen [D.1](#) taulan zehazten dira. Bestalde, atal honetan ebaluazio esanguratsuenak biltzen badira ere, proba bakoitzeko grafiko eta emaitza osagarriak [E](#) eranskinen daude ikusgai. Esperimentuek egituraturatutako trantsizio bati jarraitu diote: oinarritzko datu sintetikoetatik abiatuta, irudien sailkapenera igaro da, ondoren Weka datu-base tabularretara estrapolatu da, eta azkenik, denbora errealeko web aplikazio interaktibo baten bidez ere baliozkotu dira erabilitako teknikak, digituak errekonozitzeko testuinguruan.

6.1 Datu Sintetikoen Esperimentuak

Lehenengo fasean, oinarritzko datu sintetikoekin lan egin da, sistemaren oinarritzko funtzionamendua ziurtatzeko eta moduluen arteko integrazioa egiaztatzeko. Prozesu hau `1.1.1_data_generation_check.ipynb` eta `1.1.2_shadow_check.ipynb` fitxategien bitartez hasi da, non datuen sorkuntza eta informazio-itzalen aplikazioa zuzena zela egiaztatu den. Ondoren, `1.1.3_splitter_check.ipynb` erabili da datuen banaketa estrategiak frogatzeko.

Arazoaren konplexutasuna handitzen hasteko, `1.1_erregrezio_lineala.ipynb` garatu da. Bertan, datu linealean ereduak itzalean errore baxua mantentzen badu ere ($MSE_{\text{Shadow}} = 3.53$, datu ikusgaien 3.33 balioaren antzekoa), muga larriak agertzen dira arazo ez-linealetan. Hain zuzen, `1.2.0_erregresioak_ez_du_betirako_balio.ipynb` fitxategian sakonki aztertu denez, funtzio sinusoidal baten aurrean eredu lineala erabat desbideratzen da eta errorea hamabi aldiz handitzen da ($MSE_{\text{Shadow}} = 44.26$ vs. entrenamenduko 4.31). Fenomeno hau eta kurbadura jarraitzeko ezintasuna [E](#) eranskinen [E.1](#) irudian ikus daitezke.

Muga horiek gainditzeko asmoz, hainbat eredu konparatu dira ingurune kontrolatu honetan, funtzio sintetikoak, 3 itzal-tamaina eta erregresio-arkitektura ezberdinak


6. ESPERIMENTUAK ETA EMAITZAK

biltzen dituen esperimentu-multzoan (1.2.3_massive_benchmark.ipynb). Lortutako emaitza numeriko garrantzitsuenak 6.1 taulan biltzen dira. Bertan, **Rank Batez Bestekoa** zutabeak eredu bakoitzak proba bakoitzean lortutako posizio erlatiboaren batezbestekoa islatzen du (1 balioa errore minimoari dagokio, hots, emaitzarik onenari). Bestetik, **Top-1 Garaipenak** zutabeak adierazten du eredu bakoitza zenbat agertokitan izan den garaile nagusia ebaluatutako 45 esperimentu-konfigurazioen artean.

Eredua	Familia Teknologikoa	MSE Ikusgai	MSE Itzala	Rank Batez Bestekoa	Top-1 Garaipenak
Polynomial Degree 2	Eredu Koadratikoak	2.9922	7.4498	3.20	11 / 45
Bagging Regressor	Multzokapen Klasikoa	3.1346	7.9793	3.40	9 / 45
Polynomial Degree 5	Eredu Matematikoak	1.6927	12.0396	3.71	8 / 45
SVR RBF	Bektore Laguntzaileak	1.5869	19.3642	4.24	6 / 45
Random Forest Regressor	Erabaki Zuhaitzak	0.5612	10.9936	4.91	3 / 45
Decision Tree Regressor	Zuhaitz Bakarrek	0.7991	11.1854	5.20	1 / 45
Deep Neural Networks	Ikasketa Sakona	7.1190	28.0338	5.51	2 / 45
Linear Regression	Eredu Linealak	25.5023	72.3374	5.82	5 / 45

6.1 Taula: 50 funtzio sintetikoetan 8 erregresio-ereduren konparaketa-*benchmark* orokorra (1.2.3 koadernotik lortua).

Jarraian, 2.0.1_random_forest_uncertainty.ipynb koadernoan, erregresio-ereduek informazio-itzaletan duten bariantza eta ziurgabetasun-banda neurtu dira. 6.1 irudian ikusten den moduan, entrenamendu-datu errealetan (puntu urdinak) eta test-itzaletan (gurutze gorriak) ereduak iragarpena egitean (lerro berdea), ezjakintasun-banda gorria nabarmen zabaltzen da informazio-itzalaren eremuan.



6.1 Irudia: Random Forest erregresorearen ziurgabetasun-banda informazio-itzalaren eremuan, 2.0.1 koadernoko esperimentutik lortua.

6.2 Ekarpen Metodologikoa: Random Forest eta MC Dropout Hibridazioa

Gradu Amaierako Lan honen ekarpen metodologiko nagusietako bat ikasketa automatiko klasikoaren eta ikasketa sakon bayesiarraren arteko hibridazioa da. Literaturan, **Random Forest** (zuhaitz-multzoen bariantza estatistikoa) eta **Monte Carlo Dropout** (sare neuronaletako hurbilketa bayesiarra) paradigma independente gisa tratatu ohi dira. Lan honetan, ordea, bi familien indarguneak bateratzen dituen **EnsembleClassifier** arkitektura hibridoa diseinatu eta garatu da.

Hibridazio honen arrazoi zientifikoa bi ereduek informazio-itzaletan aurrean dituzten portaera osagarrietan oinarritzen da:

- **Monte Carlo Dropout-en mugak.** Sare neuronal konboluzionalek ezaugarri espazial hierarkikoak ikasteko gaitasun handia dute eta datu ikusgaietan asmatze-tasa oso altua lortzen dute. Hala ere, Softmax funtzioaren normalizazio-efektuaren ondorioz, entrenamenduan ikusi gabeko informazio-itzaletako datuetan gehiegizko konfiantza erakusteko arriskua dute, banaketatik kanpoko lagin batzuei entropia baxuegia esleituz.
- **Random Forest-en mugak.** Erabaki-zuhaitzek ezaugarri-espazioaren zatiketa ortogonal egiten dutenez, eremu ezezagunetan oso erantzun zuhurra ematen dute eta bariantza azkar handitzen dute. Alabaina, irudiak bektore lineal bilakatzean, datu ezagunen aurrean gehiegizko entropia adierazteko joera izaten dute.

Aipatutako mugak gainditzeko asmoz, proposatutako eredu hibridoak bi sistemen iragarpen-probabilitateak batzen ditu klase bakoitzerako:

$$\bar{p}_{\text{Ensemble}}(x)_c = \frac{1}{2} (\bar{p}_{\text{RF}}(x)_c + \bar{p}_{\text{MCDropout}}(x)_c) \quad (6.1)$$

Konbinazio honen emaitza nagusia Shannon-en entropiaren banaketa bimodal sendo bat lortzea da:

1. **Datu ezagunetan** ($H \approx 0$). Bi ereduek klase berean bat egiten dutenez, konfiantza sendotu egiten da eta entropia balio minimoetan kontzentratzen da (tontor urdina indartuz).
2. **Informazio-itzaletan** ($H \approx \log K$). Eredu bakoitzaren barne-ziurgabetasunaz gain, bi ereduen arteko desadostasuna gehitzen da. Horren ondorioz, irteerako probabilitateak klase guztien artean uniformeki banatzen dira, entropia balio maximora eramanez (tontor gorria garbi bereiziz).

Jarraian aurkeztzen diren esperimentuek erakusten dute proposatutako hibridazioak bakarkako ereduek baino OOD detekzio-zehaztasun handiagoa eta atalase estatistiko egonkorragoa lortzen duela.

6.3 Irudien Sailkapen Esperimentuak (MNIST eta CIFAR-10)

Bigarren fasean, dimentsio handiagoko datuetara igaro da esperimentazioa. MNIST (28×28) eta CIFAR-10 ($32 \times 32 \times 3$) datu-multzoetan ezkutatzeko-estrategia zientifiko ezberdinak garatu dira (`3.1_mnist_experiment.ipynb`, `3.1.1_hide_most.ipynb`, `3.1.2_hide_similar.ipynb` zein `3.1.3_ensemble.ipynb`). Datuen aurre-prozesamenduari dagokionez, MNISTeko irudietan pixelak $[0, 1]$ tartera eskalatu dira eta normalizazio estandarra aplikatu zaie ($\mu = 0.1307, \sigma = 0.3081$); ondoren, irudiak 784 dimentsioko bektore lineal bihurtu dira (*flatten*) sailkatzaile klasikoentzat, sareetan jatorrizko matrize formatua errespetatuz.

Hasieran, 3 zifra aukeratu zen ausaz. Alabaina, entropiaren analisisan argi geratu zen 3 zifra ezkutatzekoan eredu probabilistikoek entropia altua eta konfusio semantikoa agertzen zutela forma antzekoak dituzten 5 eta 8 digituekiko. Aurkikuntza horretan oinarrituta, bi esperimentu osagarri eta osotasunezko diseinatu ziren:

- **Entropia Baxueneko Zifra (1 zifra).** Lerro bakarreko zifra, bata, ezkutatu da, beste zifrekiko gainjartze eta nahaste semantiko txikiena duen kasu muga aztertzeke.
- **Antzeko Klaseen Multzoa Ezkutatu ([3, 5, 8] multzoa).** Ezaugarri bisual eta kurba antzekoak dituzten hiru digituak batera ezkutatu dira, ereduak espazio bektorialean ezaugarri egituratuagoak ikastera behartuz.

Lortutako emaitza numerikoak 6.2 eta 6.3 taulatan biltzen dira.

Ezkutatutako Klasea	Eredua	Acc Ikusgai	OOD Detekzio Acc	Entropia Muga
[3] (Kasu Nagusia)	Random Forest Classifier	94.21%	81.59%	1.46
[3] (Kasu Nagusia)	MC Dropout Classifier	93.76%	81.98%	0.42
[3] (Kasu Nagusia)	Ensemble (RF + MC Dropout)	93.42%	83.16%	1.05
[1] (Entropia Baxua)	Random Forest Classifier	89.46%	85.97%	1.63
[1] (Entropia Baxua)	MC Dropout Classifier	94.16%	84.59%	0.45
[1] (Entropia Baxua)	Ensemble (RF + MC Dropout)	93.93%	86.83%	1.14

6.2 Taula: MNIST irudietan klase bakarra ezkutatzekoaren konparaketa-benchmarka: 3 (Hasierako Kasu Nagusia) vs 1 (Entropia Baxueneko Zifra, 3.1.3 koadernotik).

Ezkutatutako Multzoa	Eredua	Acc Ikusgai	OOD Detekzio Acc	Entropia Muga
[3, 5, 8] (Antzekoak)	Random Forest Classifier	95.28%	91.67%	1.27
[3, 5, 8] (Antzekoak)	MC Dropout Classifier	95.63%	84.38%	0.10
[3, 5, 8] (Antzekoak)	Ensemble (RF + MC Dropout)	95.92%	91.58%	0.79


6.3 Taula: MNIST irudietan antzeko ezaugarri bisualak dituzten klase-multzoa [3, 5, 8] ezkutatzekoan lortutako emaitzak (3.1.3 koadernotik).

6.2 eta 6.3 tauletako emaitzen analisisan hiru ondorio atera dira:


- **Klase Bakarren Arteko Konparaketa (3 vs 1).** 1 zifra ezkutatzekoan, bere trazu bakunagatik eta gainerako digituekin gainjartze gutxi izateagatik, eredu probabilistikoek OOD detekzio handiagoa lortzen dute (%86.83 Ensemble-arekin) 3 zifrarekin baino (%83.16). 3 zifrak kurba anitz dituenek, ereduak 5 eta 8 digituekin nahasteko joera handiagoa dute.

6.3. Irudien Sailkapen Esperimentuak (MNIST eta CIFAR-10)

- **Antzeko Klaseen Multzoa ([3, 5, 8]).** Kurba eta forma antzekoak dituzten 3, 5 eta 8 digituak aldi berean ezkutatzean, erdu probabilitatekoek ezaugarri bisual orokorragoak ikasi behar dituzte ikusgaiko test-datuetaarako. Ondorioz, OOD Detekzio Zehaztasunak gailur berria lortzen du: **%91.67 Random Forest-arekin eta %91.58 Ensemble-arekin.**
- **Ensemble Teknikaren Indarra eta Abantaila.** MC Dropout-en asmatze-gaitasun handia eta Random Forest-ek ezezagunen aurrean erakusten duen ziurgabetasuna elkartzean, Ensemble-ak bi tontor oso garbi sortzen ditu entropiaren banaketan (6.4 irudia): bata ezagututako datuentzat ($H \approx 0.3$) eta bestea ezezaguntzat ($H \approx 1.5$). Eredu isolatuen aldean (6.2 eta 6.3 irudiak), bi tontorren arteko haranean ebaki-muga egonkor eta sendo bat ezartzen da ($H^* = 1.05$), ikusi gabeko datuak arazorik gabe detektatzea ahalbidetuz.




6.2 Irudia: Random Forest Classifier ereduko Konfusio Matrizea eta Entropiaren Banaketa, 3 zifra ezkutatzean (3.1.3 koadernotik).



6.3 Irudia: MC Dropout Classifier ereduko Konfusio Matrizea eta Entropiaren Banaketa, 3 zifra ezkutatzean (3.1.3 koadernotik).

6. ESPERIMENTUAK ETA EMAITZAK



6.4 Irudia: Ensemble Classifier (RF + MC Dropout) ereduko Konfusio Matrizea eta Entropiaren Banaketa Bimodala, 3 zifra ezkutatzeari (3.1.3 koadernotik).

6.3.1 CIFAR-10 Koloretako Irudien Esperimentua

Informazio-itzaen kapazitatea dimentsio altuagoko koloretako irudietan probatzeko, CIFAR-10 ($32 \times 32 \times 3$ RGB) datu-sorta erabili da `3.2_cifar-10.ipynb` koadernoan. Aurre-prozesamenduan, irudien hiru kanal kromatikoak modu independentean normalizatu dira datu-multzoko estatistikoekin ($\mu = (0.491, 0.482, 0.446)$ eta $\sigma = (0.202, 0.199, 0.201)$), eta eredu klasikoetarako 3072 dimentsioko bektore bilakatu dira. Esperimentu honetan 3 klasea (Katua) erabat ezkutatu da entrenamendutik, eta irudi konplexuetarako bereziki garatutako `CNNMCDropoutClassifier` arkitektura konboluzionala ebaluatu da Random Forest ereduarekin konparatuz. Lortutako emaitzak 6.4 taulan biltzen dira.

Eredua	Ezkutatutako Klasea	Acc Ikusgai	Acc Itzala	Entropia Ikusgai	Entropia Itzala	OOD Detekzio Acc
Random Forest Classifier	3 (Katua)	38.53%	0.00%	1.9117	1.9871	52.40%
CNN MC Dropout Classifier	3 (Katua)	61.35%	0.00%	0.4273	0.6256	68.70%

6.4 Taula: CIFAR-10 koloretako irudietan 3 klasea (Katua) ezkutatzean lortutako konparaketa eta OOD detekzioaren zehaztasuna (3.2 koadernotik).


6.4 taulako emaitzek argi erakusten dutenez, sarrerako datuen dimentsionaltasunak, kolore-kanalek eta objektu errealeen konplexutasun semantikoak, MNISTeko trazu sinpleen aldean, esperimentuaren zailtasuna nabarmen handitzen dute. Konplexutasun gehigarri horren ondorioz, OOD detekzioaren zehaztasunean emaitza kaxkarragoak lortzen dira. MNISTen lortutako %83.16–%91.67ko zehaztasun altuen aurrean, CIFAR-10en zehaztasunak jaitsi egiten dira, %52.40 Random Forest-arekin eta %68.70 CNN MC Dropout-arekin. Beherakada honek frogatzen du ezaugarri-espazioa zailtzen denean oinarritzko eredu probabilistikoen mugak agerian geratzen direla, eta irudi konplexuetan ziurgabetasuna hautemateko arkitektura konboluzional sakonagoak ezinbestekoak direla.

6.4 Datu tabularren bidez balioztapena

Azken fasean, Weka biltegiko datu-base tabular estandarrek erabiliz, itzaldutako datuen detekzioan sakondu da, `ClosestClusterShadow` bidez zentroide zentralena ezkutatuz.

Datu-multzoak hautatzeko irizpideari dagokionez, gomendatutako datu-baseen artetik atributu guztiak zenbakizkoak zituztenak soilik aukeratu dira, eredu probabilitikoei distantzia euklidearrak, bariantzak eta klusterren zentroideak ezaugarri-espazio jarraituan zuzenean kalkula ditzaten. Horrela, sei datu-base hautatu dira (*housing*, *pbz*, *quake*, *cpu_act*, *cal_housing* eta *mv*), eta haien ezaugarri zein emaitza numerikoak 6.5 eta 6.6 tauletan ikus daitezke.

Datu tabular hauen tratamenduan aurre-prozesamendu estandarra gauzatu da: balio galduak dituzten erregistroak ezabatu dira (`dropna`), eta balizko aldagai kategorikoak *One-Hot Encoding* bidez kodetu dira. Gainera, zenbakizko ezaugarrietan normalizazioa aplikatu da, ezaugarri bakoitzaren eskala ezberdinek PCA bidezko 2D proiektzioan eta klusterizazioan distantziak desitxuratu ez ditzaten. Ezaugarri tabular multidimentsionalak 2D ardatzetara proiektatu eta zentroide zentralaren informazio-itzala bistaratzeko `src/visualization.py` moduluko `plot_weka_pca` funtzioa erabili da (6.5 irudian erakusten den moduan).



6.5 Irudia: Weka Quake datu-multzoko datuen proiektzioa PCA bidez 2D-n, `plot_weka_pca` funtzioarekin marraztua: entrenamendu-datuak (urdina), ikusgaiko test-datuak (ziana) eta `ClosestClusterShadow` bidez ezkutatutako zentroide zentralaren itzala (gorria).

Ohiko K-Fold balioztatze gurutzatuaren eta informazio-itzalen arteko aldea agerian uzteko, 6.5 taulan alderatzen dira eredu bakoitzak ikusgaiko datuetan (MSE_{Vis} , ausazko banaketa estandarrean lortua) eta itzaldutako eremuan (MSE_{Shadow}) lortutako errore koadratiko ertainak. Datuetan argi ikusten da ohiko K-Fold CV-k emaitza oso baikorrak eta errore baxuak erakusten dituela, baina ereduak informazio-

6.4. Datu tabularren bidez balioztapena

itzalera igarotzean errorea bikoiztu edo hirukoiztu egiten dela (adibidez, *housing* datu-multzoan Ensemble-aren errorea 7.32tik 18.39ra handitzen da, +%151.2).

Datu-multzoa	Eredua	Ohiko CV (MSE_{Vis})	Itzala (MSE_{Shadow})	Errorearen Hazkundera
housing	Random Forest	8.10	19.16	+136.5%
housing	BNN	9.85	21.00	+113.2%
housing	Ensemble	7.32	18.39	+151.2%
quake	Random Forest	0.0385	0.0428	+11.2%
quake	BNN	0.1244	0.2391	+92.2%
quake	Ensemble	0.0428	0.0508	+18.7%
cpu_act	Random Forest	7.93	7.23	-8.8%
cpu_act	BNN	37.01	52.45	+41.7%
cpu_act	Ensemble	15.72	30.93	+96.8%
pbc	Random Forest	1.16×10^6	1.47×10^6	+26.7%
pbc	BNN	1.19×10^6	1.34×10^6	+12.6%
pbc	Ensemble	1.12×10^6	1.24×10^6	+10.7%
cal_housing	Random Forest	2.64×10^9	3.03×10^9	+14.8%
cal_housing	BNN	1.43×10^{10}	2.04×10^{10}	+42.7%
cal_housing	Ensemble	6.15×10^9	8.88×10^9	+44.4%
mv	Random Forest	0.0157	0.0152	-3.2%
mv	BNN	0.2907	0.1807	-37.8%
mv	Ensemble	0.1491	0.1633	+9.5%


6.5 Taula: Ohiko balioztatze gurutzatuaren (MSE_{Vis}) eta informazio-itzaleko ebaluazioaren (MSE_{Shadow}) arteko konparaketa eredu ezberdinetan.

Behin baikortasun faltsu hori zenbakiz egiaztatuta, 6.6 taulan eta 6.6 irudian Kluster Bidezko Balioztatze Gurutzatuaren OOD detekzio-zehaztasuna eta Ezjakintasun Ratioak aztertzen dira:

Datu-multzoa	Itzal Metodologia	Eredua	OOD Detekzio Acc	Ezjakintasun Ratioa
housing	ClosestClusterShadow	Random Forest	55.78%	1.24
housing	ClosestClusterShadow	BNN	66.25%	1.41
housing	ClosestClusterShadow	Ensemble	61.37%	1.46
pbc	ClosestClusterShadow	Random Forest	55.74%	1.15
pbc	ClosestClusterShadow	BNN	47.46%	1.36
pbc	ClosestClusterShadow	Ensemble	56.98%	1.32
quake	ClosestClusterShadow	Random Forest	54.42%	0.95
quake	ClosestClusterShadow	BNN	92.32%	1.63
quake	ClosestClusterShadow	Ensemble	80.41%	1.44
cpu_act	ClosestClusterShadow	Random Forest	49.95%	1.03
cpu_act	ClosestClusterShadow	BNN	45.36%	19.18
cpu_act	ClosestClusterShadow	Ensemble	45.89%	53.62
cal_housing	ClosestClusterShadow	Random Forest	56.73%	1.12
cal_housing	ClosestClusterShadow	BNN	57.08%	1.56
cal_housing	ClosestClusterShadow	Ensemble	66.93%	1.62
mv	ClosestClusterShadow	Random Forest	51.00%	1.00
mv	ClosestClusterShadow	BNN	48.10%	1.04
mv	ClosestClusterShadow	Ensemble	50.47%	1.01

6.6 Taula: Weka datu-base tabularretan Kluster Bidezko Balioztatze Gurutzatuarekin eredu ezberdinek lortutako OOD Detekzio Zehaztasuna eta Ezjakintasun Ratioak.

6.6 taulako emaitzek frogatzen dutenez, arazoaren dimentsioa eta zailtasuna handitzean (CIFAR-10 bezalako irudietan eta Weka datu-base tabularretan), OOD detekzioaren emaitzak apalak izaten dira (%45.59 eta %68.70 artean). Ezaugarri-espazioa zailtzen denean, garatutako oinarritzko eredu probabilitistikoak sinpleegiak geratzen dira informazio-itzalak modu zorrotzean detektatzeko. Ebaluazio honetan laginak ezagunak ala informazio-itzalekoak diren bereizten denez, ausazko asmatze-maila edo zoria %50ekoa (0.5) da, 6.6 irudiko marra gorriak adierazten duen moduan.



6.6 Irudia: Weka datu-base tabularretan Kluster Bidezko Balioztatze Gurutzatuarekin eredu ezberdinek (RF, BNN eta Ensemble) lortutako OOD Detekzio Zehaztasunaren konparaketa-grafikoa. Marra gorriak zoriaren erreferentzia adierazten du (%50), laginak ezagunak ala itzalekoak diren bereiztean.


6.5 Karaktereen Web Aplikazioaren Balioztatze Interaktiboa

Garatutako arkitekturaren ikuspegi praktikoa eta denbora errealeko aplikagarritasuna egiaztatzeko, `src/3.1.4_karaktereen_web_aplikazioa` aplikazio interaktiboaren bidezko esperientzia gauzatu da. Zerbitzariak denbora errealean erantzuten die erabiltzaileak Canvas bidez marraztutako sarrerei.


Ebaluazio interaktibo honetan aplikazioak denbora errealean kudeatzen dituen gertaera nagusiak eta ikasketa jarraituko prozesu osoa ikus daitezke:

1. **Ikusgaiko Karaktereen Sailkapen Arina.** Erabiltzaileak entrenamenduko zifra ezagunak marrazten dituenean (6.7 irudiko 7 zifra gisa), Ensemble ereduak eta interpretatzaileak entropia oso baxua ($H = 0.319$) eta konfiantza altua (%92.6) neurtzen dituzte, seinale berdea emanez.
2. **Denbora Errealeko OOD Detekzioa.** Erabiltzaileak informazio-itzaleko karaktere ezezagun bat marraztean (6.8 irudiko Q karakterea gisa), Ensemble ereduak ezjakintasuna probabilitate uniformearen banatzen du, entropia altua lortuz ($H = 1.798$). Interpretatzaileak muga zeharkatu dela detektatzen du ($\tau^* = 1.72$) eta seinale gorria pizten du OOD alerta emanez.
3. **Izendapena eta Lagin Eskaria.** Erabiltzaileak kategoria berria sortzea aukeratzean, karakterearen izena zehazten du (6.9 irudiko Q izena). Nahikoa lagin bildu ez badira, aplikazioak oharra biltzen du ($H = 1.255$ entropia altuegia dela adieraziz 6.10 irudian).
4. **Lagin Bilketa eta Birrentrenatzea.** Erabiltzaileak karaktere berriaren lagin anitz marrazten eta gordetzen ditu (6.11 irudiko 33/35 laginak gisa). Lagin bilduma osatzean, `/train_new_class` zerbitzuak Ensemble ereduaren denbora errealean berriro entrenatzen du.
5. **Birrentrenatutako Ereduaren Inferentzia.** Laginak bildu eta entrenatu ondoren (v61c9d4 bertsioan, 6.12 irudia), Q karakterea berriro marraztean, sistemak klase berri gisa hautematen du %70.2ko konfiantzaz eta entropia $H = 1.154$ -ra jaitsiz, klase berria arrakastaz inkorporatu duela frogatuz.

6. ESPERIMENTUAK ETA EMAITZAK




6.7 Irudia: Karaktereen Web Aplikazioa '7' zifra ezaguna marraztean.




6.8 Irudia: Karaktereen Web Aplikazioa 'Q' karaktere ezezaguna marraztean.

6.5. Karaktereen Web Aplikazioaren Balioztatze Interaktiboa




6.9 Irudia: Karaktere berria irakasteko interfazea.




6.10 Irudia: Fase-egiaztapeneko oharra.

6. ESPERIMENTUAK ETA EMAITZAK



6.11 Irudia: Ikasketa jarraituko lagin-bilketa.



6.12 Irudia: Birrentrenatutako ereduaren (v61c9d4) inferentzia arrakastatsua.

Ondorioak eta Etorkizuneko Lanak

7.1 Ondorio Nagusia

Ikasketa Automatikoko eredu ezberdinek informazio-itzaletan eta ikusi gabeko inguruneetan duten portaera, ziurgabetasunaren estimazioa eta ezkutatutako datuen detekzioa aztertu dira. Proiektuko esperimentu eta garapen guztietatik atera daitekeen ondorio nagusi eta sendoena honela biltzen da.

*Sare neuronal estandarrek informazio-itzaletan erakusten duten gehiegizko konfiantza ez da marjinala edo zorizkoa, baizik eta arkitektura deterministen egiturazko ezintasun baten ondorioa. Arazo horri aurre egiteko, ziurgabetasun probabilistikoaren estimazio bimodala eta giza begizta aktiboa uztartzea **tresna egoki eta itxaropentsua** izan daitekeela erakutsi da egindako esperimentazioen testuinguruan, bide horretan urrats sendoak emanez. Proiektu honek agerian utzi du ezinbestekoa dela sistemek gutxienez berezko bideren bat izatea beren ezjakintasuna aitortzeko eta informazio-itzaletan arriskurik gabeko erantzunak emateko.*

7.2 Esperimentazio-Ardatzen Emaita

Proiektuko lau fase esperimentalean lortutako aurkikuntza esanguratsuenak honako ardatz hauetan laburbiltzen dira.

1. Erregresioaren eta Sailkapenaren Arteko Neurketa Bideak.

- Erregresio-iragarpenetan, ziurgabetasuna iragarpenen arteko bariantza edo desbideratze estandarraren bidez neurtzea bide aproposa dela erakutsi da egindako esperimentuetan. Eredu probabilistikoek ikusgaiko datu-espazioan bariantza txikia eta zirrikitu zein itzalpeko eremuetan ezjakintasun-banda zabala erakusten dute.

- Irudien sailkapenean, berriz, Shannon-en Entropia agertu da ziurgabetasuna neurtzeko adierazle baliagarri gisa. Testuinguru horretan, Entropia Banaketaren Grafiko Bimodalak itzaldutako datuen detekzioarako ebaluazio-bide oso argigarria eskaintzen duela ikusi da.

2. Random Forest Ereduaren Sendoera eta Informazio Uniformea.

- Random Forest ereduak, berezko *bootstrap* laginketari esker, itzaldutako klase ezezagunen aurrean probabilitate uniformea banatzen dute klase guztien artean. Horri esker, entropia-tontor garbia eskuinera eraman eta itzaldutako datuen bimodalitatea lortzen dute, gehiegizko konfiantza saihestuz.
- Halere, dimentsio handiko irudietan, esaterako, CIFAR-10 datu-basean, ezaugarri-erazketa optiko ahula dutenez, ikusgaiko test zehaztasuna murriztu egiten da.

3. Sare Neuronal Estandarraren Gehiegizko Konfiantza eta Ensemble Kalibratua.

- Sare neuronal tradizionalak eta MC Dropout bidezko egokitzapen sinpleek gaitasun handia dute ezaugarriak erazteko, baina ezkutatutako klase ezezagunen aurrean gehiegizko konfiantza larria erakusten dute.
- Bi familien mugak aztertuta, lan honen ekarpen metodologiko berritzaile gisa garatu den **EnsembleClassifier** eredu hibridoak (Random Forest-en zuhurtzia eta Sare Neuronalen ahalmen diskriminatzailea uztartzen dituen) konpromiso-erlazio bikaina eskaintzen du. Emaitzak ikusita bilakaera natural eta logikoa bazen ere, bi familien arteko fusio honek lan honen ekarpen propio eta berritzailea osatzen du: ikusgaiko zehaztasun altua mantentzen du eta itzalean entropia maximoa berreskuratzen du, entropiaren banaketan bimodalitate garbia bermatuz.

4. Entropia Mugaren (H^*) Kalibrazioa eta Egonkortasun Ideala.

- Sailkapen probabilistikoan, informazio-itzaleko datuak hautemateko gako nagusia entropia muga (H^*) egoki ezartzea da. Eredu isolatuek muga muturretara eramaten dute: MC Dropout-ek, itzalean duen gehiegizko konfiantzagatik, muga oso baxua behar du ($H^* = 0.42$), eta horrek ikusgaiko datu legitimoak eremu ezezaguntzat oker jotzeko arriskua handitzen du; Random Forest-ek, aldiz, ikusgai duen bariantzagatik muga oso altua behar du ($H^* = 1.46$), itzaleko datu batzuk ez detektatzea eraginez.
- Konfigurazio idealak bi tontorren arteko bereizketa maximoa bilatzen du: datu ikusgaiak entropia minimora eramatea ($H \rightarrow 0$), itzalpekoak entropia maximora bultzatzea ($H \rightarrow \log K$), eta bien artean dentsitate nuluko haran zabala eratzea. Testuinguru horretan, atalase optimoa tartearen erdialdean kokatzea komeni da ($H^* \approx \frac{1}{2} \log K$, MNISTen $H^* \approx 1.05$ lortu den gisan). Erdibideko kokapen honek tolerantzia handia eskaintzen dio sistemari, zarata edo banaketaren aldaketa txikien aurrean OOD detekzioaren zehaztasuna egonkor mantenduz.

5. Zirrikrituen bidezko Balioztatze Metodologikoa.

- Ohiko K-Fold balioztatze gurutzatuak datu guztiak ausaz nahasten dituelako, testeko adibideak entrenamenduko oso gertu geratu ohi dira. Prozedura horrek datu errealak entrenamendu-marko berean gertatuko direla suposatzen du, eta zentzu horretan, baikortasun faltsu bat sorrarazi diezaguke banaketatik kanpoko eremuen aurrean. Proiektu honetan garatutako **GapSplitter** (tarte jarraituak ezkutatuz) eta **ClosestCluster Shadow** (erdiko klusterra ezkutatuz) bidezko balioztatzeei esker soilik lortu da eredu probabilitistikoek informazio-itzalen aurrean duten benetako portaera eta ziurgabetasuna azaleratzea.

6. Etengabeko Ikasketa eta Giza Begizta Web Aplikazioan.

- Garatutako karaktereen web aplikazioak frogatu du OOD detekzioa ez dela mugatzen diagnostiko estatiko batera. Entropia altuko sarrera ezezagunak detektatzean, aplikazioak giza begizta aktiboa aktibatzen du, lagin berriak bilduz eta eredia denbora erreal berriz entrenatuz.

7.3 Garatutako Ereduen eta Esperimentuen Mugak eta Gabeziak

Esperimentazio-fasean agertutako muga eta gabezia tekniko nagusiak honako hauek dira.

1. **Entropia-Lausotzea eta Test Zehaztasunaren Trukea.** Multzokatze-ereduak (**EnsembleClassifier**) Random Forest-en bariantza eta MC Dropout-en ezaugarri-erauzketa bateratzean, probabilitateen batezbestekoak tontor bakoitzaren zorrotasuna apur bat lausotzen du. Gainera, eredu osagaien arteko desadostasunak ikusgaiko test zehaztasunean beherakada arina dakar eredu indibidual idealenekin alderatuta, OOD detekzio sendago baten truke.
2. **Dimentsionaltasun Handiko eta Datu Tabularren Zailtasunak.** Sarrerako datuen dimentsionaltasuna, kolore-kanalak eta forma ez-linealak handitzean, OOD detekzioaren zehaztasunak beherakada jasaten du. Eraitza kaxkarrago hauek frogatzen dute oinarritzko eredu hauek sinpleegiak geratzen direla ingurune izugarri konplexuetarako.
3. **Sare Neuronal Bayesiarren (BNN) Ezegonkortasuna.** Nahiz eta literaturan BNN ereduak ziurgabetasunaren estimaziorako erreferentzia nagusitzat jo, egindako esperimenduetan muga praktikoak agertu dira. Alde batetik, datu sintetikoetan ezjakintasuna itzalean zehatz lokalizatu ordez domeinu osoan zehar homogeneizatzeko joera erakutsi dute (E.4 irudian ikus daitekeen gisan). Bestetik, datu tabularretan portaera oso gorabeheratsua izan dute; izan ere, datu-multzo batzuetan OOD detekzio sendoa lortu arren (*quake* kasuan %92.32), beste batzuetan zoriaren azpitik geratu dira (%45–%48 artean, 6.6 taulan jaso bezala). Eraitza horiek erakusten dute BNN ereduaren kalibrazioa ez dela beti zuzena, eta horregatik lehenetsi dira irudien esperimenduetan MC Dropout bezalako hurbilketak.

7.4 Etorkizuneko Lan Ildoak

Lan honetan lortutako emaitza eta garatutako software-arkitekturan oinarrituta, hiru ikerketa-ildo nagusi irekitzen dira.

- **Hizkuntza Eredu Handiak, Informazio-Itzalak eta Haluzinazioen Murrizketa.** Srivastava eta Chatterjeeren [1] azken ikerketa teorikoek agerian utzi duten moduan, Hizkuntza Eredu Handiek (LLM) egiturazko informazio-itza gaindiezinak dituzte, eta entrenamendu-banaketatik at dauden eremuetan ezin dute ezagutza berririk modu autonomoan sortu. Oinarrian sare neuronal deterministak dituztenez, itzalpeko eremu horietan ezjakintasuna aitortu ordez gehiegizko konfiantzaz erantzuteko joera dute, haluzinazio-arazo larriak eraginez. Lan honetan garatutako itzalen kontzientzia duen ziurgabetasunaren estimazioa (*shadow-aware uncertainty*), entropia bimodalaren kalibrazio-sistemak eta giza begizta aktiboa LLM arkitekturetan integratzea ikerketa-ildo oso emankorra eta beharrezkoa da.
- **OOD Detekzioa Denbora Errealeko Sistema Txertatueta.** Garatutako muga-kalkulua denbora errealeko inferentzia-sistematar bideratzea (adibidez ibilgailu autonomotara edo diagnostiko medikora), ikusi gabeko sarreraren aurrean erantzun seguruak bermatzeko asmoz.
- **Arkitektura Sakonagoak eta Ezaugarri Sakonen Erauzketa.** Diment-sionaltasun handiko irudietan eta ingurune konplexuetan lortutako zehaztasun-beherakada gainditzeko, etorkizuneko bide gisa aurrez entrenatutako ezaugarri-erauzle sakonagoak eta arkitektura hibridoak uztartzea proposatzen da. Ezaugarri sakon eremu horietan ziurgabetasun-metrikak eta informazio-itzalak aplikatuz, ingurune izugarri konplexuetan OOD detekzioaren gaitasuna eta zehaztasuna nabarmen hobetzeko asmoz.

AA sortzailearen erabilera deklarazioa

informazio gehiago: <https://www.ehu.eus/eu/web/adimen-artifiziala/home>

Erabilitako tresna/k:

Google Gemini, Antigravity IDE

Egindako erabilera (dagokiona markatu):

- ☐ Testu-sorkuntza
- ☒ Birformulazioa
- ☐ Itzulpena / zuzenketa
- ☒ Egituraren iradokizuna
- ☒ Laguntza metodologikoa
- ☒ Kodetzeko / programatzeko laguntza
- ☐ Beste batzuk

Egindako erabileraren deskribapena:

Adimen Artifizial Sortzailea zeregin osagarrietan erabili da lan honetan zehar, hots, karaktereen web aplikazio interaktiboaren interfazea eta zerbitzari-egitura garatzeko, proiektuaren arkitektura orokorraren eskemak eta plangintza bideratzeko laguntza metodologiko gisa, eta memoriako testuen idazkera orrazteko zein $\text{\LaTeX}$ egituraren doikuntza teknikoak gauzatzeko. Ikerketaren ardatz nagusi diren informazio-itzalen formulazio matematikoa, eredu probabilitistikoak, OOD detekzio-mekanismoak eta esperimentazio-koadernoak eskuz programatu, aztertu eta garatu dira.

A. AA SORTZAILEAREN ERABILERA DEKLARAZIOA

Autoretza konpromisoa:

Sortutako eduki guztia pertsonalki berrikusi, berregin eta balioztatu dudala bermatzen dut.

Erabiltzailearen eta Implementazioaren Manuala

Eranskin honetan proiektuko software-arkitektura exekutatzeke, koadernoak prozesatzeko eta Karaktereen Web Aplikazioa abiarazteko jarraibide tekniko eta erabilera-gida biltzen dira.

B.1 Software Betebeharrak eta Ingurunea

Sistemak Python 3.10+ ingurunea behar du. Garatutako moduluek komunitate zientifikoko liburutegi nagusiak erabiltzen dituzte. Exekuzio egoki baterako dependentzia hauek instalatuta egon behar dute.

- **torch** eta **torchvision**. Sare Neuronal Sakonak eta Bayesiarrak inplementatzeko eta MNIST/CIFAR-10 datu-baseak prozesatzeko.
- **scikit-learn**. Random Forest, Ensemble eta balioztatze gurutzatuko egiturak kudeatzeko.
- **pandas** eta **numpy**. Datu-egiturak matrize eta DataFrame formatu estandarretan manipulatzeko.
- **matplotlib** eta **seaborn**. Emaizta grafikoak eta KDE entropia-banaketak bistaratzeko.
- **flask**. Karaktereen web aplikazioaren zerbitzari interaktiboa abiarazteko.

Ingurune birtual bat sortu eta dependentziak instalatzeko komandoak honako hauek dira.

```
# Ingurune birtuala sortu eta aktibatu
python3 -m venv .venv
source .venv/bin/python3/activate
```

```
# Dependentsia nagusiak instalatu
pip install torch torchvision scikit-learn pandas numpy \
    matplotlib seaborn flask
```

B.2 Esperimentu Koadernoaren Exekuzioa

Proiektuko 20 koaderno zientifikoak `notebooks/` direktorioan kokatzen dira. Koaderno hauek exekutatzeke, proiektuaren erroko direktorioan Jupyter zerbitzaria abiarazi behar da.

```
jupyter notebook notebooks/
```

Koadernoek zenbaketa logiko bati jarraitzen diote. Datu sintetikoaren sorkuntzatik abiatuta (1.1.x), erregresio analisisian sakontzen da (1.2.x), jarraian ziurgabetasun-neurri probabilitistikoak inplementatzen dira (2.x), irudien sailkapenera igarotzen da (3.x), eta azkenik Weka datu-base tabularrak balioztatzen dira (4.x).

B.3 Karaktereen Web Aplikazioaren Erabilera (3.1.4 Esperimentua)

Proiektu osoan zehar publikoki ikus daitezkeen iturburu-kode bakarra karaktereen web aplikazioari dagokiona da (3.1.4 esperimentua). Web interfaze interaktiboaren eta atzealdearen kode hau GitHub-eko https://github.com/gorkiiuss/mnist_eskalatua biltegian dago eskuragarri.

Zerbitzaria abiarazteko komandoa honako hau da.

```
python app.py
```

Zerbitzaria hasieratu ondoren, nabigatzailean `http://localhost:5000` helbidera jo behar da. Interfazeak honako osagai hauek eskaintzen dizkio erabiltzaileari.

1. **HTML5 Canvas Marrazketa Tailerra.** Erabiltzaileak saguaren bidez karakterea marraz dezake 28×28 bereizmeneko panel inbertituan.
2. **Sailkapen eta Entropia Panela.** Erabiltzaileak *Sailkatu* botoia sakatzean, Ensemble ereduak klase bakoitzaren probabilitatea eta Shannon-en entropia $H(p)$ kalkulatu dituen denbora errealean.
3. **Informazio-Itzalen Alerta.** Entropia kalkulatu muga kritikoa baino altuagoa denean ($H(p) > 1.24$), aplikazioak seinale gorria pizten du informazio-itzala eta ezezaguna den karakterea detektatu duela jakinaraziz.
4. **Ikasketa Jarraituko Berrirako Entrenatzea.** Karaktere ezezagun bati etiketa berri bat esleitu eta *Entrenatu Klase Berria* sakatzean, aplikazioak `/train_new_class` endpoint-a deitzen du eta Ensemble ereduaren denbora errealean berregokitzen du.



Koadernoen eta Esperimentuen Inbentario Osoa

Proiektuan gauzatutako esperimentu bakoitzaren helburua, erabilitako datu-basea eta lortutako aurkikuntza nagusiak [C.1](#) taulan biltzen dira.

Koaderno Fitxategia	Datu-basea / Ingurunea	Aurkikuntza eta Helburu Nagusia
1.1.1_data_generation_check.ipynb	Math2D Sintetiko	BaseDataGenerator interfazearen proba.
1.1.2_shadow_check.ipynb	1D / 2D Sintetiko	BandShadow eta zarataren injekzioaren froga.
1.1.3_splitter_check.ipynb	GapSplitter Sintetiko	Visible eta Shadow test multzoen banaketa.
1.1_erregrezio_lineala.ipynb	Erregresio Lineala	Oinarriko MSE errorearen neurketa.
1.2.0_erregresioak_ez_du_betirako.ipynb	Funtzio Sinusoidalak	Eredu linealen muga handiak ($MSE > 44.26$).
1.2.1_multi_model_benchmark.ipynb	1D Sintetiko	Eredu klasikoaren arteko MSE konparaketa.
1.2.2_fitting_models_to_curves.ipynb	Kurben Doikuntza	SVR eta Polynomial ereduen portaera.
1.2.3_massive_benchmark.ipynb	50 Funtzio Sintetiko	DNN (Mean Rank 3.46) eta RF (4.32) nagusitasuna.
2.0.1_random_forest_uncertainty.ipynb	Erregresio Banatua	RF bariantzaren neurketa ($\sigma_{shadow}^2 = 0.184$).
2.1_informazioaren_bila.ipynb	Informazio-itzalak	Informazioaren eta datuen arteko bereizketa.
2.2_dropout_desberdinak.ipynb	Dropout Sareak	Dropout proportzio optimoa ($p = 0.2 - 0.3$).
2.3_modelo_bayesianak.ipynb	BayesianLinear	Barietateko inferentzia eta ELBO froga.
3.1_mnist_experiment.ipynb	MNIST Irudiak	0 Klasea ezkatutuz bimodalitatearen analisisa.
3.1.1_mnist_experiment_hide_most.ipynb	MNIST Irudiak	1 Klase errazena ezkatutuz bimodalitatea.
3.1.2_mnist_experiment_hide_similar.ipynb	MNIST Irudiak	1 eta 7 klase antzekoak ezkatutuz bimodalitatea.
3.1.3_mnist_experiment_ensemble.ipynb	MNIST Irudiak	Ensemble (RF+NN) OOD Detekzioa (%98.20).
3.1.4_karaktereen_web_aplikazioa	Canvas / Web Interaktiboa	Web aplikazioa: OOD detekzioa, giza etiketatzea eta berriz entrenatzea.
3.2_cifar-10.ipynb	CIFAR-10 RGB Irudiak	Dimentsio handiko irudien entropiaren analisisa eta OOD detekzioa.
4.1_weka_experiments.ipynb	Weka Datu Tabularrak	Weka datu-baseen kargatzea eta iragaztea.
4.2_weka_ood_detection.ipynb	Weka Datu Tabularrak	Tabularretako informazio-itzaletan ebaluazioa.
4.3_weka_cluster_cv.ipynb	Housing, Quake, CPU Act	ClosestClusterShadow eta PCA 2D proiektzioak.

C.1 Taula: Proiektuko esperimentu eta koaderno inbentario zein laburpen tekniko osoa (3.1.4 esperimentua web aplikazio interaktibo gisa garatu baita).

Hiperparametroak eta Ereduen Konfigurazioak

Esperimentu bakoitzaren errepikagarritasuna bermatzeko asmoz, [D.1](#) taulan erabilitako eredu probabilistiko nagusien hiperparametroen balio zehatzak eskaintzen dira.

Eredua	Hiperparametroa	Erabilitako Balio Estandarra
Random Forest Classifier	Zuhaitz Kopurua (<code>n_estimators</code>)	50 zuhaitz
Random Forest Classifier	Gehienezko Sakonera (<code>max_depth</code>)	15 maila
Random Forest Classifier	Ausazko Hazia (<code>random_state</code>)	42
MC Dropout NN	Ezkatuko Dimentsioak (<code>hidden_dim</code>)	128 MNIST / 64 Tabular
MC Dropout NN	Dropout Proportzioa (<code>dropout_rate</code>)	$p = 0.30$
MC Dropout NN	Epoka Kopurua	50 epoka
MC Dropout NN	Optimizatzailea eta Ikaste-tasa (LR)	Adam, $\eta = 0.001$
MC Dropout NN	Inferentzia Iterazioak (<code>n_iter</code>)	$T = 30$ edo $T = 50$
Bayesian Neural Network	Hasierako Pisuaren Banaketa	$\mathcal{N}(\mu = 0.0, \sigma^2 = 0.1)$
Bayesian Neural Network	ρ Hasierako Balioa	$\rho_{\text{init}} = -3.0$
Ensemble Classifier	Osagaien Pisuak	Batez besteko uniformea ($w_i = 1/M$)
UncertaintyInterpreter	Muga Kandidatuak	100 urrats (<code>np.linspace</code>)

D.1 Taula: Esperimentuetan erabilitako eredu probabilistikoen hiperparametroen konfigurazio osoa.

Esperimentazioaren Emaidza eta Grafiko Gehigarriak


Eranskin honetan proiektuko hogei koaderno esperimentaletan lortutako grafiko eta emaitza nagusiak biltzen dira, arrakastak zein agertutako muga teknikoak labur aztertuz.

E.1 Datu Sintetikoak eta Erregresio Ez-linealaren Ebaluazioa



Lehen koaderno-multzoan oinarritzko ereduen portaera aztertu zen ingurune sintetiko kontrolatuetan, itzal-tamaina ezberdinak erabiliz.

[E.1](#) irudian erregresio linealaren porrota ikus daiteke funtzio sinusoidal ez-lineal batean, 1.2.0 koadernoan garatua. Eredu linealak ezin du kurbadura jarraitu, eta informazio-itzalaren eremuan 44.26ko batez besteko errore koadratikoa sortzen du.

Porrot horren aurrean, 1.2.1 koadernoan hainbat eredu ez-lineal ebaluatu ziren. [E.2](#) irudian ikus daitekeenez, bigarren mailako eredu polinomialak (ezkerrean) eta Random Forest erregresoreak (eskuinean) interpolazio arrakastatsua lortzen dute kurbadura zirkularreko itzal txikietan, muturren arteko jarraitutasuna bermatuz.



E.1 Irudia: Erregresio linealaren porrota funtzio sinusoidal ez-linealean, kurbadura ikasi ezinik desbideratze handia sortuz (1.2.0 koadernotik).




E.2 Irudia: Koadernoetako eredu arrakastatsuak kurba zirkularreko itzalean, bigarren mailako polinomiala ezkerrean eta Random Forest eskuinean (1.2.1 koadernotik).

E.2 Ziurgabetasun Probabilistikoa eta Bariaziozko Inferentzia


Bigarren koaderno-multzoan ziurgabetasuna kuantifikatzeko mekanismo probabilistikoa eta haien muga praktikoak ebaluatu ziren.

[E.3](#) irudian, 2.2 koadernotik ateratakoan, Monte Carlo Dropout sareen portaera aztertzen da $p = 0.20$ eta $p = 0.40$ dropout-tasak erabiliz. Lortutako emaitzek ziurgabetasunaren desegokitzapena utzi zuten agerian. Informazio-itzalaren eremuan ereduak konfiantza gehiegi erakusten du, ezjakintasun-banda murrizta eskainiz, eta datu ikusgaietan, aldiz, ezjakintasun gehiegi adierazten du.



E.3 Irudia: MC Dropout sareen ebaluazioa $p = 0.20$ ezkerrean eta $p = 0.40$ eskuinean, itzalpeko gehiegizko konfiantza eta ikusgaiako ezjakintasun desegokia erakutsiz (2.2 koadernotik).

Bestalde, [E.4](#) irudian, 2.3 koadernokoan, Sare Bayesiarren porrot experimentalak aurkezten da. Datu sintetikoetan Sare Bayesiarrek informazio-itzalari egokitutako ezjakintasun lokalizatua erakustea espero zen arren, emaitzetan ez zen bilatutako arrakastarik lortu. BNN ereduak ezjakintasun-banda zabal eta homogeneoa hedatzen du domeinu osoan zehar, itzalpeko eremua eta datu ikusgaiak bereizi gabe.




E.4 Irudia: Sare Neuronal Bayesiarren porrot esperimentalaren datu sintetikoetan, ezjakintasun-banda eremu osoan homogeneoki hedatuz (2.3 koadernotik).

E.3 Irudien Ezkutatze Eszenatokiak: Eredu Estandarrak vs. Ensemble Bimodala


Hirugarren koaderno-multzoan irudien sailkapenean eredu estandar deterministek eta Ensemble eredu probabilistikoek duten portaera konparatu zen.

E.5 irudian, MNIST datu-multzoan klaseak ezkutatzean lortutako entropia-dentsitateen banaketak alderatzen dira. Ezkerreko grafikoan, MC Dropout eredu estandarrek gehiegizko konfiantza erakusten du ezkutatutako klasean, itzalaren entropia balio baxuetan pilatuz. Eskuineko grafikoan, ordea, Ensemble ereduak bimodalitate garbia lortzen du, datu ikusgaiak entropia baxuan eta ezezagunak entropia altuan kokatuz.



E.5 Irudia: MNIST entropia-dentsitateen konparaketa, MC Dropout isolatuaren gain-konfiantza ezkerrean eta Ensemble ereduaren bimodalitate garbia eskuinean (3.1 eta 3.1.3 koadernoetatik).

Dimentsio handiagoko CIFAR-10 irudietan, 3.2 koadernoan eta **E.6** irudian ikus daitekeenez, pixel lauak erabiltzearen muga agerian geratu zen. Random Forest ereduaren test zehaztasuna ehuneko 42.3ra jaitsi zen, ezaugarri-erazle konboluzional sakonagoen beharra frogatuz.




E.6 Irudia: CIFAR-10 irudietan entropia-banaketan analisia eta dimentsionaltasun handiaren ondorioak (3.2 koadernotik).

E.4 Weka Datu Tabularretako PCA Kluster-Itzalen Galeria Osoa


Laugarren koaderno-multzoan mundu errealeko datu tabularrak ebaluatu ziren ClossClusterShadow mekanismoaren bidez.

E.7 irudian aztertutako Weka datu-base tabular guztien bi dimentsioko PCA proiektzioak aurkezten dira, hala nola *California Housing*, *Boston Housing*, *CPU Activity*, *Quake*, *MV* eta *PBC*. Proiektzio hauetan argi ikusten da k-means algoritmoak kluster zentroideak isolatzen dituela, informazio-itzalak entrenamenduko datuetatik egituraz banatuz.



E.7 Irudia: Weka datu-base tabularretan PCA dimentsio-murrizketa eta k-means bidezko zentroide isolatuen informazio-itzalen galeria osoa (4.1 eta 4.3 koadernoetatik).

Weka datu-base tabular hauetan guztietan kluster bidezko baliozkotze gurutzatu-an eredu desberdinek lortutako OOD detekzio-zehaztasunaren konparaketa-barra grafikoa E.8 irudian erakusten da.



E.8 Irudia: Weka datu-base tabularretan kluster bidezko baliozkotze gurutzatuarekin eredu desberdinek lortutako OOD detekzio-zehaztasunaren konparaketa (4.3 koadernotik).

E.8 irudiko emaitzek esperimentu-multzo honen muga eta porrot orokorra uzten dute agerian. Ereduen OOD detekzio-zehaztasuna oso apala da datu tabularretan, hainbat kasutan ehuneko 50 inguruko ausazko sailkapenaren mugatik oso gertu geratuz. Porrot horren arrazoi nagusia bi faktoreren arteko desoreka handian datza, hots, garatutako iragarpen-sistemen sinpletasuna eta datu-base tabularrek duten gehiegizko konplexutasuna, dimentsionaltasun altua eta aldagaien arteko erlazio ez-linealak. Emaitza apal hauek frogatzen dute datu tabular konplexuetarako egitura sakonagoak beharrezkoak direla.

Bibliografia

- [1] Priyansh Srivastava and Romit Chatterjee. The information shadow: Measuring structural limits on what language models can learn. *arXiv preprint arXiv:2607.18305*, 2026. Ikusi [1](#), [48](#) orrialdeak.
- [2] Charles Blundell, Julien Cornebise, Koray Kavukcuoglu, and Daan Wierstra. Weight uncertainty in neural networks. In *International Conference on Machine Learning (ICML)*, pages 1613–1622, 2015. Ikusi [11](#), [13](#), and [27](#) orrialdeak.
- [3] Diederik P Kingma and Max Welling. Auto-encoding variational bayes. In *International Conference on Learning Representations (ICLR)*, 2014. Ikusi [13](#), [27](#) orrialdeak.
- [4] Yarin Gal and Zoubin Ghahramani. Dropout as a bayesian approximation: Representing model uncertainty in deep learning. *International Conference on Machine Learning (ICML)*, 2016. Ikusi [14](#) orrialdea.
- [5] Balaji Lakshminarayanan, Alexander Pritzel, and Charles Blundell. Simple and scalable predictive uncertainty estimation using deep ensembles. *Advances in Neural Information Processing Systems (NeurIPS)*, 2017. Ikusi [14](#) orrialdea.
- [6] Nathaniel S. O’Connell. Random forests as statistical procedures: Design, variance, and dependence. *arXiv preprint arXiv:2602.13104*, 2026. Ikusi [14](#) orrialdea.
- [7] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001. Ikusi [14](#) orrialdea.
- [8] Alex Kendall and Yarin Gal. What uncertainties do we need in bayesian deep learning for computer vision? In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, 2017. Ikusi [15](#) orrialdea.
- [9] Weitang Liu, Xiaoyun Wang, John Owens, and Yixuan Li. Energy-based out-of-distribution detection. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, 2020. Ikusi [15](#) orrialdea.
- [10] Dan Hendrycks and Kevin Gimpel. A baseline for detecting misclassified and out-of-distribution examples in neural networks. In *International Conference on Learning Representations (ICLR)*, 2017. Ikusi [15](#) orrialdea.
- [11] Chuan Guo, Geoff Pleiss, Yu Sun, and Kilian Q Weinberger. On calibration of modern neural networks. In *International Conference on Machine Learning (ICML)*, pages 1321–1330, 2017. Ikusi [15](#) orrialdea.
- [12] Claude E Shannon. A mathematical theory of communication. *The Bell System Technical Journal*, 27(3):379–423, 1948. Ikusi [15](#) orrialdea.
- [13] Anastasios N Angelopoulos and Stephen Bates. A gentle introduction to conformal prediction and distribution-free uncertainty quantification. *arXiv preprint arXiv:2107.07511*, 2021. Ikusi [16](#) orrialdea.
- [14] David R Roberts, Viki Bahn, Simone Ciuti, Mark S Boyce, Jane Elith, Gema Guillerá-Arroita, et al. Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, 40(8):913–929, 2017. Ikusi [17](#) orrialdea.

BIBLIOGRAFIA

- [15] Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, et al. Pytorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 8024–8035, 2019. Ikusi [19](#) orrialdea.
- [16] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, et al. Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12:2825–2830, 2011. Ikusi [19](#) orrialdea.
- [17] Mark Hall, Eibe Frank, Geoffrey Holmes, Bernhard Pfahringer, Peter Reutemann, and Ian H Witten. The weka data mining software: An update. *SIGKDD Explorations*, 11(1):10–18, 2009. Ikusi [19](#) orrialdea.
- [18] Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998. Ikusi [23](#) orrialdea.
- [19] Alex Krizhevsky. Learning multiple layers of features from tiny images. *Master’s thesis, University of Toronto*, 2009. Ikusi [24](#) orrialdea.